



REPÚBLICA BOLIVARIANA DE VENEZUELA
UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA
VICERRECTORADO ACADÉMICO
COORDINACIÓN GENERAL DE PREGRADO
PROYECTO DE CARRERA: INGENIERÍA EN INFORMÁTICA

**SISTEMA DE RECOMENDACIÓN BASADO EN GRAFOS DE
INTERACCIÓN PARA UN SISTEMA E-COMMERCE.**

Tutora:

Dra. Padilla, Virginia

Autores:

Fabian Trillo

Heiner Enis

Ciudad Guayana, Diciembre de 2024



REPÚBLICA BOLIVARIANA DE VENEZUELA
UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA
VICERRECTORADO ACADÉMICO
COORDINACIÓN GENERAL DE PREGRADO
PROYECTO DE CARRERA: INGENIERÍA EN INFORMÁTICA

**SISTEMA DE RECOMENDACIÓN BASADO EN GRAFOS DE
INTERACCIÓN PARA UN SISTEMA E-COMMERCE.**

Tutora:

Dra. Padilla, Virginia

Autores:

Fabian Trillo

C.I.: 26.382.781

Heiner Enis

C.I: 27.729.230

Ciudad Guayana, Diciembre de 2024



UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA

COORDINACIÓN GENERAL DE PREGRADO

COORDINACIÓN DE ING. EN INFORMÁTICA

ACTA DE EVALUACIÓN DE TRABAJO DE GRADO

Los suscritos, reunidos hoy 11/12/2024 a las 9:00 AM, en la sede de Villa Asia, miembros del Jurado designado por la Comisión de Trabajo de Grado según control CGT/036/17, de fecha 24 de Abril de 2017 cumplidos con todos los aspectos formales para la Presentación Oral y Pública y en atención a lo dispuesto en el Artículo 32 del Reglamento de Trabajo de Grado de Pregrado de la Universidad Nacional Experimental de Guayana (UNEG), para evaluar el Trabajo de Grado titulado: "SISTEMA DE RECOMENDACIÓN BASADO EN GRAFOS DE INTERACCIÓN PARA UN SISTEMA E-COMMERCE" presentado por los bachilleres: HEINER ALEJANDRO ENIS CAICEDO C.I. V27729230 y FABIAN ALEJANDRO TRILLO MALAVE C.I. V26382781 en cumplimiento con lo establecido en el mismo reglamento, para optar al grado de Ing. en Informática, hacemos constar que habiéndolos evaluado hemos acordado emitir el siguiente veredicto:

Aprobado con mención: Honorífica y Publicación.

Presidente del Jurado: _____

Prof: URICARE P, ROSANGEL J
C.I.:V12891739

Primer Miembro: _____

Prof: COVA CARMA, AIMARA AZUCENA
C.I.:V13090589

Segundo Miembro _____

Prof: HUAMAN HUAMAN ANA YSABEL
C.I.:V22824279

Tutor Académico: _____

Prof: PADILLA VIRGINIA DEL VALLE
C.I.:V05521766

Código de Verificación CACE: 5786AD7AF





UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA

COORDINACIÓN GENERAL DE PREGRADO

COORDINACIÓN DE ING. EN INFORMÁTICA

ACTA DE MENCIÓN DE TRABAJO DE GRADO

Los suscritos, reunidos hoy 11/12/2024 a las 9:00 AM, en la sede de Villa Asia, miembros del Jurado designado por la Comisión de Trabajo de Grado según control CGT/036/17, de fecha 24 de Abril de 2017 cumplidos con todos los aspectos formales para la Presentación Oral y Pública y en atención a lo dispuesto en el Artículo 32 del Reglamento de Trabajo de Grado de Pregrado de la Universidad Nacional Experimental de Guayana (UNEG), para evaluar el Trabajo de Grado titulado: "SISTEMA DE RECOMENDACIÓN BASADO EN GRAFOS DE INTERACCIÓN PARA UN SISTEMA E-COMMERCE" presentado por los bachilleres: HEINER ALEJANDRO ENIS CAICEDO C.I. V27729230 y FABIAN ALEJANDRO TRILLO MALAVE C.I. V26382781 dieron como veredicto: Aprobado con mención: Honorifica, ya que posee un tratamiento novedoso y significativo del tema investigado, en tanto constituye un aporte diferente al área y/o tema abordado, posee una pertinencia contextual del problema abordado (el problema de investigación y sus resultados responden a demandas claramente establecidas de orden social, institucional, disciplinar o de otro orden), articula de manera clara y precisa los aspectos estructurales medulares del trabajo; a saber: problema, objetivos, metodología y resultados, posee una fundamentación teórica suficiente y adecuada al tema, al problema y a aquellos aspectos identificados como relevantes y hace uso claro y preciso de la lengua en el desarrollo de su texto académico, donde se diferencia de manera formal las ideas propias y ajenas con su respectiva identificación de la fuente. Los abajo firmantes dan fé de todo lo anterior.

Presidente del Jurado: _____

Prof: URICARE P, ROSANGEL J

C.I.:V12891739

Primer Miembro: _____

Prof: COVA CARMA, AIMARA AZUCENA

C.I.:V13090589

Segundo Miembro _____

Prof: HUAMAN HUAMAN ANA YSABEL

C.I.:V22824279





UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA

COORDINACIÓN GENERAL DE PREGRADO

COORDINACIÓN DE ING. EN INFORMÁTICA

ACTA DE ARGUMENTACIÓN A LA MENCIÓN PUBLICACIÓN

Los abajo firmantes, jurados del trabajo de grado intitulado: "SISTEMA DE RECOMENDACIÓN BASADO EN GRAFOS DE INTERACCIÓN PARA UN SISTEMA E-COMMERCE", presentado por los bachilleres: HEINER ALEJANDRO ENIS CAICEDO C.I. V27729230 y FABIAN ALEJANDRO TRILLO MALAVE C.I. V26382781, para optar al título de Ingenieros en Informática; una vez evaluado su contenido, recomendamos la Mención Publicación por considerar que:

- El tema es novedoso, porque permite conocer como funciona un sistema de recomendación basado en grafos de interacción para un sistema e-commerce. Cabe destacar que los autores destacan la utilización de una herramienta de última tecnología para comprar y vender por internet.
- Pertinente al área de Informática y a la realidad de las organizaciones del sector comercial.
- Muestra un manejo metodológico coherente con la naturaleza del problema estudiado.
- Posee una fundamentación teórica que por sí misma es un aporte a las investigaciones sobre el tema.
- Posee un nivel de complejidad acorde al título de Ingeniero en Informática.

En Ciudad Guayana, a los 11 días del mes de diciembre de 2024

Presidente del Jurado: _____

Prof: URICARE P, ROSANGEL J
C.I.:V12891739

Primer Miembro: _____

Prof: COVA CARMA, AIMARA AZUCENA
C.I.:V13090589

Segundo Miembro _____

Prof: HUAMAN HUAMAN ANA YSABEL
C.I.:V22824279



REPUBLICA BOLIVARIANA DE VENEZUELA
UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA
VICERRECTORADO ACADÉMICO
COORDINACIÓN GENERAL DE PREGRADO
PROYECTO DE CARRERA: INGENIERIA EN INFORMATICA

APROBACIÓN DEL TUTOR

En mi carácter de Tutor del Trabajo "SISTEMA DE RECOMENDACIÓN BASADO EN GRAFOS DE INTERACCIÓN PARA UN SISTEMA E-COMMERCE.", presentado por los estudiantes: Fabian Trillo, cédula de identidad N° 26.382.781 y Heiner Enis, cédula de identidad N° 27.729.230, como un requisito para optar al grado de Ingeniero en Informática, considero que dicho Trabajo de Grado reúne los requisitos y méritos suficientes para ser sometido a evaluación por parte del jurado examinador.

En Ciudad Guayana, a los días del mes de Diciembre de 2024.

Firma



Dra. Padilla, Virginia

C.I: 5.521.766

ÍNDICE GENERAL

ÍNDICE GENERAL	ii
LISTA DE FIGURAS.....	vi
LISTA DE TABLAS.....	ix
RESUMEN	x
INTRODUCCIÓN.....	1
CAPÍTULO I	3
EL PROBLEMA	3
Descripción del problema.....	3
Formulación del problema.....	6
Objetivos de la investigación.....	7
Objetivo General	7
Objetivos Específicos	7
Justificación de la investigación	7
Alcance de la investigación	8
CAPÍTULO II	10
MARCO TEÓRICO.....	10
Antecedentes	10
Sistemas de recomendación y explicaciones basados en grafos de interacción.....	10
Desarrollo de un sistema de recomendaciones para un sitio de comercio electrónico	12
Bases Teóricas	13
Sistemas de recomendación (SR)	14

Tipos de sistemas de recomendación	14
Sistemas de recomendación basados en grafos	16
Técnicas de predicción de enlaces.....	17
Métodos de agregación para recomendadores basados en grafos	18
Aprendizaje automático	20
Render	20
Rango intercuartílico (RIC)	22
K – means	23
Kernel.....	24
Factorización de matrices no negativas	25
Modelo de predicción de enlaces ACCSLP	27
K fold target encoding.....	30
Métricas de evaluación de técnicas de predicción de enlace	31
Descomposición en valores singulares (SVD)	33
Cron job.....	34
Python	34
Pandas	34
Scikit-learn.....	35
NumPy	35
PostgreSQL.....	35
Metodología.....	36
Estilo de arquitectura del sistema.....	39
CAPÍTULO III.....	44

MARCO METODOLÓGICO	44
Tipo de investigación	44
Diseño de la investigación	44
Población y muestra	45
Técnica de Recolección de datos	47
Revisión documental	47
Cuestionario	47
Fases de la investigación	48
CAPÍTULO IV	50
ANÁLISIS, INTERPRETACIÓN Y PRESENTACIÓN DE LOS RESULTADOS	50
Fase 1: Analizar la teoría existente sobre sistemas de recomendación y técnicas de predicción de enlaces	50
Revisar documentos, investigaciones, y artículos científicos	51
Adaptar las teorías y resultados de las ciencias básicas al proyecto de investigación	51
Fase 2: Definir y analizar los requerimientos del sistema	53
Metodología de desarrollo	53
Definición y análisis de requerimientos	54
Fase 3. Diseñar el sistema, modelo arquitectónico, estructura de datos e interfaces	55
Establecer la arquitectura del sistema de recomendación de acuerdo a los requerimientos previamente definidos	55
Colección de datos a utilizar	57
Identificar los datos abstractos y sus relaciones	59

Fase 4. Desarrollar el sistema de recomendación basado en técnicas de predicción de enlaces	60
Procesamiento de los datos	61
Preparación de los datos.....	61
Obtención de la información para el modelo del sistema de recomendación.....	72
Construcción del sistema de recomendación.....	80
Recomendación de los productos.....	82
Despliegue del sistema de recomendación.....	83
Fase 5. Evaluar la precisión del sistema de recomendación.....	84
Evaluar la precisión del modelo.....	85
Evaluar la precisión de las listas de recomendación	89
Evaluar la aceptabilidad de las recomendaciones por los usuarios	96
CONCLUSIONES.....	100
RECOMENDACIONES.....	101
REFERENCIAS	102
ANEXOS	108
A. Modelo relacional de la base de datos.....	109
B. Formato de cuestionario para los usuarios del e-commerce	111
C. Respuestas emitidas por los encuestados	113
D. Caso de uso Consultar productos.....	114
E. Manual de usuario del sistema	116
F. Manual del sistema.....	122

LISTA DE FIGURAS

1. Proceso de recomendación llevado a cabo con el grafo de interacción.....	18
2. Rango Intercuartílico.....	22
3. Agrupación de puntos de datos utilizando el algoritmo K-means ...	24
4. Esquema del modelo ACCSLP.....	29
5. Modelo en cascada	37
6. Patrón de arquitectura Separación de la Lógica de Negocio de los Modelos de ML.....	40
7. Patrón de arquitectura Gateway-Routing.....	41
8. Arquitectura Lambda para ML	42
9. Arquitectura del sistema de recomendación.....	56
10. Modelo Entidad - Relación de la base de datos.....	60
11. Distribución de la columna Actual_price	62
12. Diagrama de caja de la característica Actual_price	63
13. Valores anormales en la columna Actual_price	64
14. Distribución de la característica Actual_price después de eliminar los valores anormales.....	65
15. Aplicación de la transformación logarítmica de base 10 en la columna Actual_price	65
16. Distribución de la característica Actual_price_log.....	66
17. Cálculo del promedio de precio de los productos por categoría ...	68
18. Codificación de la columna Category_name utilizando K-fold target encoding	69
19. Distribución de la característica Category_name_encoded	71
20. Transformación logarítmica de base 10 aplicada sobre Category_name_encoded	71
21. Distribución de la característica Category_name_encoded después de aplicar la transformación logarítmica de base 10.....	72

22. Consulta SQL para obtener el número de usuarios que han interactuado con cada par de productos.....	73
23. Número de usuarios que han interactuado con los primeros 30 pares de productos.	74
24. Construcción de la matriz de adyacencia	75
25. Submatriz de adyacencia para los primeros 20 nodos de la red...	76
26. Obtención de la matriz de pertenencia utilizando el algoritmo de agrupamiento K-means	77
27. Submatriz de pertenencia a una comunidad para los primeros 20 nodos de la red	78
28. Implementación de la medida de similitud RBF kernel	79
29. Submatriz de similitud de atributos para los primeros 10 nodos de la red	79
30. Descomposición de las matrices de adyacencia, pertenencia a una comunidad, y similitud de atributos	80
31. Proceso de factorización de matrices no negativas	81
32. Función de divergencia generalizada de Kullback – Leibler	82
33. Dashboard de Render con los servicios implementados	84
34. Enlaces inexistentes del grafo de interacción	85
35. Enlaces de evaluación para el cálculo del índice AUC	86
36. Submatriz de adyacencia de entrenamiento para los primeros 20 nodos de la red	87
37. Submatriz de predicción para los primeros 20 nodos de la red	88
38. Cálculo del índice AUC.....	89
39. Lista de productos con los que han interactuado los usuarios.....	90
40. Lista de productos de evaluación para el cálculo de la medida precision@k	91
41. Pares de enlaces a eliminar para el usuario con ID 5.....	92
42. Eliminación de interacciones del usuario objetivo de la lista de interacciones.	93

43. Conjunto de interacciones después de eliminar las interacciones del usuario con ID 5.....	93
44. Submatriz de adyacencia para los primeros 20 nodos de la red, después de eliminar las interacciones del usuario con ID 5.....	94
45. Lista de recomendación para el usuario con ID 5.....	95
46. Cálculo de la medida precision@k	95
47. Facilidad para encontrar recomendaciones relevantes.....	96
48. Nivel de precisión de las recomendaciones.....	97
49. Diversidad de las recomendaciones	98
50. Probabilidad de recomendar el sistema de recomendación a otras personas	98
51. Modelo relacional de base de datos.	110
52. Respuestas emitidas por los usuarios.	113
53. Mapa de navegación del sistema e-commerce.....	117
54. Formulario de registro en el sistema.....	118
55. Formulario de inicio de sesión	118
56. Página de inicio de la plataforma con recomendaciones para el usuario	119
57. Listado de productos del e-commerce para la categoría de cámaras.	120
58. Página de detalles del producto	121

LISTA DE TABLAS

1. Comparación de diferentes sistemas de recomendación.....	51
2. Adopción de los elementos teóricos en la investigación	52
3. Diccionario de datos del dataset de productos	57
4. Productos agrupados por categorías.....	67
5. Categorías de productos codificadas.....	69
6. Descripción del caso de uso de gestión de carro de compras.....	114
7. Requerimientos para la ejecución del sistema en un entorno local	123
8. Requerimientos para el despliegue del sistema	123

REPÚBLICA BOLIVARIANA DE VENEZUELA
UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA
VICERRECTORADO ACADÉMICO
COORDINACIÓN GENERAL DE PREGRADO
PROYECTO DE CARRERA: INGENIERÍA EN INFORMÁTICA

**SISTEMA DE RECOMENDACIÓN BASADO EN GRAFOS DE
INTERACCIÓN PARA UN SISTEMA E-COMMERCE.**

Autores: Fabian Trillo y Heiner Enis

Tutor: Dra. Virginia Padilla

Fecha: Diciembre 2024

RESUMEN

Esta investigación tiene como objetivo desarrollar un sistema de recomendación basado en grafos de interacción para predecir las futuras interacciones de los usuarios con productos en una plataforma de e-commerce. Para ello, se combinó una investigación documental y de campo, revisando la literatura sobre sistemas de recomendación y técnicas de predicción de enlaces. Se utilizó la metodología CRISP-DM, reconocida en proyectos de ciencia de datos. Además, se empleó el lenguaje de programación Python y las librerías Scikit-learn, NumPy y Pandas para el procesamiento de datos y la implementación de técnicas de aprendizaje automático. La precisión del sistema se evaluó según el rendimiento general del modelo y su capacidad para predecir correctamente las interacciones de los usuarios. Como resultado, se presenta una solución innovadora que mejora la personalización de las recomendaciones.

Palabras clave: sistema de recomendación, aprendizaje automático, grafos, predicción de enlaces

INTRODUCCIÓN

Los sistemas de recomendación son herramientas esenciales para personalizar la experiencia del usuario y optimizar los resultados en diversas plataformas digitales. Estos sistemas analizan grandes volúmenes de datos generados por las interacciones de los usuarios, como compras, ratings y visualizaciones de contenido, para ofrecer recomendaciones altamente personalizadas que se alinean con los intereses y necesidades específicas de cada individuo. Al aprovechar estas fuentes de información, los sistemas de recomendación no solo mejoran la satisfacción del usuario, sino que también incrementan la interacción y la lealtad hacia la plataforma.

El propósito principal de estos sistemas es maximizar la visibilidad y relevancia de los productos o servicios ofrecidos, con la finalidad de mejorar la experiencia del usuario y alcanzar objetivos clave, como el aumento de ventas o la retención de clientes. Sin embargo, una limitación común es la falta de información suficiente sobre las preferencias y comportamientos de los usuarios, lo que presenta un desafío significativo. En este contexto, el reto es desarrollar estrategias que permitan recopilar y utilizar de manera eficiente los datos disponibles para generar recomendaciones precisas y relevantes, incluso en entornos con conocimiento limitado.

Así, en esta investigación, el enfoque central consiste en desarrollar un sistema de recomendación el cual será probado en una plataforma de e-commerce para su evaluación. Esto permitirá demostrar su aplicación práctica y medir su rendimiento en un entorno real. Este trabajo se organiza en varios capítulos que presentan de manera secuencial el desarrollo de la investigación propuesta, abordando cada etapa de manera exhaustiva.

En el Capítulo I, se introduce el problema de investigación, se delinean los objetivos generales y específicos, se justifica la relevancia del estudio y se establece el alcance de la investigación.

El Capítulo II ofrece una revisión de los antecedentes relevantes para esta investigación, además de abordar las bases teóricas necesarias para comprender y contextualizar el sistema propuesto.

El Capítulo III expone la metodología fundamentada que guiará la investigación, detallando el tipo de estudio y describiendo las distintas fases que se llevarán a cabo.

El Capítulo IV presenta los resultados obtenidos, incluyendo la ingeniería de las características, el modelado de la base de datos, y el análisis de las medidas de precisión del sistema de recomendación.

Finalmente, el trabajo concluye con un resumen de las conclusiones alcanzadas, las recomendaciones derivadas del estudio y los anexos que complementan la investigación.

CAPÍTULO I

EL PROBLEMA

Descripción del problema

En la actualidad, con el crecimiento del comercio en línea, los usuarios tienen acceso a una amplia gama de productos para consumir. La oferta disponible en la web es prácticamente infinita, brindando a los usuarios la ventaja de tener más opciones para encontrar los productos que desean. Sin embargo, esta variedad también puede resultar abrumadora, a la hora de localizar los productos más adecuados para cada usuario. Para abordar este problema, surgen los sistemas de recomendación. Según [Philip, Shola, y Abari \(2014\)](#), estos sistemas son aplicaciones de software que brindan sugerencias o recomendaciones de elementos a los usuarios, basándose en sus preferencias e intereses.

Antes de la existencia de los sistemas de recomendación en el comercio electrónico (*e-commerce*, en inglés), las tiendas en línea enfrentaban varios desafíos. Los usuarios tenían que realizar búsquedas ineficientes en extensos catálogos. Además, la ausencia de personalización hacía que las recomendaciones fueran generales y no se ajustaran a las necesidades específicas de los usuarios. La sobrecarga de información y opciones afectaba la toma de decisiones de los usuarios, y la escasez en el descubrimiento de

nuevos productos limitaba las oportunidades de venta cruzada. Todo esto impactaba la retención de clientes en las tiendas en línea. No obstante, con la llegada de los sistemas de recomendación, los comercios electrónicos han podido superar estos problemas, ofreciendo recomendaciones precisas y relevantes que mejoran la experiencia del usuario, aumentando así la retención de clientes y enriqueciendo la experiencia de compra en línea.

En este contexto, [Martínez \(2022\)](#) destaca que los sistemas de recomendación han sido desarrollados con el propósito de determinar los productos más adecuados para los intereses de los usuarios, con el objetivo de ayudarles en la toma de decisiones. Estos sistemas han sido objeto de estudio durante muchos años y se encuentran ampliamente presentes en diversas plataformas de nuestro día a día, como Netflix, Amazon, y Spotify. Una de las técnicas emergentes en este campo es el uso de sistemas de recomendación basados en grafos.

Es importante comenzar definiendo qué es un grafo, este es “una estructura computacional que representa las entidades de un sistema y las relaciones entre ellas” ([Martínez, 2022, p.21](#)). En el contexto de los sistemas de recomendación, los grafos se utilizan para modelar las relaciones entre usuarios y productos. Los nodos en el grafo representan los productos con los que han interactuado los usuarios, y los enlaces representan la relación o interacción que existe entre los nodos, de ahí el nombre de grafos de interacción. El uso de grafos de interacción permite integrar información sobre usuarios, productos y otros atributos del sistema para mejorar la calidad de las recomendaciones y abordar problemas como la dispersión y el arranque en frío (*cold start*, en inglés).

Como se mencionó anteriormente, en los sistemas de recomendación, la dispersión se produce cuando “solo se realiza una pequeña proporción de interacciones entre los usuarios y los productos, de entre todas las posibles combinaciones” ([Martínez, 2022, p.27](#)). Por otro lado, el problema del *cold start*

está relacionado con la “generación de recomendaciones para nuevos usuarios, cuyo historial de consumo es pequeño y poco relevante” ([Silva, Carvalho, Pereira, Mourão, y Rocha, 2019, p.3](#)). Estos problemas han sido identificados como desafíos importantes en el desarrollo de sistemas de recomendación, y es precisamente por ello que se propone el uso de grafos de interacción como una solución para abordar estos inconvenientes.

A nivel internacional, [Linden, Smith, y York \(2003\)](#) presentan el caso de la corporación Amazon, esta empresa utiliza extensivamente algoritmos de recomendación para personalizar su sitio web según los intereses de cada cliente. De esta manera, la compañía desarrolló su propio algoritmo denominado como “filtrado colaborativo de artículo a artículo” (*item-to-item collaborative filtering*, en inglés), el algoritmo en lugar de comparar al usuario objetivo con clientes similares, este empareja cada artículo comprado y evaluado por el usuario con artículos similares, y luego combina esos artículos similares en una lista de recomendaciones. Así, para determinar la coincidencia más similar para un artículo dado el algoritmo crea una tabla de artículos similares encontrando artículos que los clientes tienden a comprar juntos.

A nivel nacional, [Valecillos \(2020\)](#) implementó un sistema de recomendación para el sitio web e-commerce Aprovecha.com el cual se dedica a la venta de cupones de descuentos en distintas categorías tales como gastronomía, belleza, y viajes, entre otros. El sistema de recomendación estuvo basado en filtrado colaborativo, para ello utilizó el histórico de compras de los usuarios de la plataforma como fuente de información a objeto de predecir los ítems a recomendar. Las recomendaciones son obtenidas mediante el cálculo de las similitudes entre usuarios.

Considerando los antecedentes y el contexto actual del problema, se propone desarrollar un sistema de recomendación basado en grafos de

interacción, que brindará soporte a un sitio web de e-commerce dedicado a la venta de productos electrónicos.

En concordancia con el propósito de la investigación, el objetivo principal del sistema de recomendación es predecir recomendaciones relevantes. La interacción constante entre los usuarios y los productos permitirá que el sistema se adapte dinámicamente a los cambios en el comportamiento del cliente, asegurando que las recomendaciones siempre estén actualizadas y sean relevantes.

Formulación del problema

En este orden de ideas, para llevar a cabo la investigación conducente a lograr la meta propuesta, se plantean las siguientes interrogantes:

¿Cuáles son los principios de los sistemas de recomendación?

¿Cuáles son los requerimientos necesarios para desarrollar un sistema de recomendación basado en grafos de interacción?

¿Cuál es la arquitectura de software que cumple con las características necesaria para implementar el sistema propuesto?

¿Cuáles metodologías y herramientas se adaptarían mejor al sistema a desarrollar?

¿Cómo se diseñaría el sistema de recomendación de acuerdo a la arquitectura seleccionada?

¿Cómo se validará la precisión del sistema de recomendación basado en grafos de interacción?

Objetivos de la investigación

Objetivo General

Desarrollar un sistema de recomendación basado en grafos de interacción para un sistema e-commerce.

Objetivos Específicos

- 1) Analizar los principios de los sistemas de recomendación.
- 2) Analizar los requerimientos para el desarrollo de un sistema de recomendación basado en grafos de interacción.
- 3) Identificar la arquitectura de software que cumple con las características necesarias para implementar el sistema propuesto.
- 4) Determinar las herramientas y metodologías más adecuadas para el desarrollo del sistema.
- 5) Diseñar el sistema de recomendación con la arquitectura de software seleccionada.
- 6) Realizar mediciones para validar la precisión del sistema de recomendación basado en grafos de interacción.

Justificación de la investigación

El desarrollo de un sistema de recomendación basado en grafos de interacción para un e-commerce se justifica por su capacidad para utilizar la mínima cantidad de información disponible para generar recomendaciones. Esto permite abordar la falta de datos inicial en sistemas nuevos y la dispersión típica de muchas redes existentes en el mercado, superando las limitaciones

de los métodos tradicionales, que suelen depender de grandes volúmenes de datos.

Desde el punto de vista social este sistema permitirá que los usuarios obtengan recomendaciones personalizadas que enriquezcan su experiencia de compra, lo que a su vez fomenta la confianza y la lealtad hacia la plataforma. Además, mejorará la capacidad de ventas en el comercio electrónico.

Así mismo, esta investigación ayudaría a contribuir en el avance de los sistemas de recomendación al aplicar técnicas de predicción de enlaces y métodos de aprendizaje no supervisado. Estas técnicas permiten abordar el problema de la falta de información mediante la extracción de datos complementarios. Este enfoque no solo resuelve un desafío crítico en los sistemas de recomendación, sino que también sienta las bases para futuras investigaciones en áreas con problemas similares.

Alcance de la investigación

El presente proyecto se enfoca en el desarrollo de un sistema de recomendación basado en grafos de interacción, diseñado para predecir los productos con los que los usuarios podrían interactuar en el futuro. La investigación abarca:

1. El diseño y construcción de un modelo que utiliza como fuente de información las características de los productos y las interacciones de los usuarios.
2. El análisis, selección y preprocesamiento de los datos necesarios para alimentar el modelo de recomendación.
3. El despliegue del modelo como una solución funcional.

Los usuarios interactuarán con el sistema de recomendación a través de una plataforma de e-commerce, diseñada para capturar y almacenar el

historial de interacciones entre los usuarios y los productos. Esta plataforma servirá como interfaz para alimentar el modelo de recomendación con datos relevantes. Para la implementación, se utilizaron los servicios de computación en la nube de Render, específicamente el servicio web para el despliegue de la plataforma de e-commerce y el servicio de base de datos PostgreSQL para persistir la información obtenida de los usuarios

Cabe destacar que el desarrollo completo de la plataforma de e-commerce queda fuera del alcance de esta investigación, limitándose únicamente a su utilización como soporte de datos para el sistema de recomendación.

Las funcionalidades principales del sistema de recomendación son las siguientes:

- Extraer atributos de los productos mediante técnicas de aprendizaje no supervisado.
- Entrenar el modelo de recomendación para generar una matriz de predicciones.
- Construir listas de recomendación personalizadas para cada usuario, basadas en los valores de similitud obtenidos.

CAPÍTULO II

MARCO TEÓRICO

Antecedentes

La investigación está sustentada bajo diversos estudios relacionados a la implementación de sistemas de recomendados de productos, los cuales abarcan la explicación de sus fundamentos teóricos, implementación, validación de los resultados, y propuesta de mejoras.

Los antecedentes de la investigación tomados para este trabajo, constan de trabajos de grados nacionales e internacionales.

Sistemas de recomendación y explicaciones basados en grafos de interacción

La tesis doctoral realizada por [Marta Martínez](#) en 2022 y presentada ante la Universidad Complutense de Madrid, España, aborda las limitaciones inherentes a los sistemas tradicionales de recomendación y explicación. Estos sistemas, que se apoyan principalmente en las valoraciones de los usuarios y las descripciones de productos, enfrentan dificultades cuando esta información no está disponible en ciertas circunstancias, lo que resalta la necesidad de

buscar alternativas. El enfoque principal de este estudio se dirige hacia situaciones de "mínimo conocimiento", donde la única información disponible sobre los usuarios son las interacciones que han tenido con los productos.

El objetivo central es proponer una alternativa a los métodos convencionales, buscando obtener resultados comparables o incluso superiores, y todo ello con la ventaja de requerir menos información. Para lograr este propósito, se propuso la utilización de grafos de interacción en conjunto con técnicas de predicción de enlaces, con el fin de crear recomendaciones y explicaciones en escenarios caracterizados por niveles mínimos de información.

Los resultados obtenidos permitieron el desarrollo de un sistema de recomendación que cumple con cada uno de los objetivos planteados para abordar las hipótesis del trabajo, generando recomendaciones explicables y visualizables.

Esta tesis doctoral sienta las bases para la construcción de sistemas de recomendación basados en grafos en un contexto de conocimiento limitado, siendo su principal contribución los fundamentos para el desarrollo de un modelo de recomendación.

A diferencia de la tesis de Martínez, que se centra en el uso de métodos de similitud locales y se limita a la información de los nodos vecinos en el grafo, el sistema de recomendación que se desarrolló emplea la técnica de factorización de matrices no negativas. Este enfoque permite predecir los enlaces utilizando tanto la topología de la red como las características de los elementos.

Desarrollo de un sistema de recomendaciones para un sitio de comercio electrónico

[Oscar Valencillo](#) llevó a cabo un proyecto de grado en 2019, el cual presentó ante la Universidad Central de Venezuela (UCV). En este proyecto, se diseñó un sistema de recomendación para el sitio web [aprovecha.com](#), con el fin de fomentar las ventas cruzadas y mejorar la experiencia del usuario.

El propósito de esta investigación fue desarrollar, diseñar e implementar un sistema de recomendación. Se empleó un enfoque basado en el filtrado colaborativo basado en memoria, que utiliza las calificaciones de los usuarios hacia las categorías de los productos que han adquirido como fuente de información. Además, se utilizó el algoritmo de similitud de coseno para calcular la similitud entre usuarios basándose en sus calificaciones.

Como resultado, se obtuvo un modelo capaz de predecir la valoración que un usuario podría otorgar a los productos de una categoría específica. Esto cumplió con los objetivos del proyecto, logrando así generar recomendaciones para los usuarios objetivo basadas en los datos gestionados por la empresa.

Las contribuciones de este estudio ofrecen una perspectiva sobre cómo aprovechar los atributos de los productos para calcular los valores de similitud entre ellos. Además, proporcionan un enfoque para utilizar la información disponible en la realización de predicciones y simular un entorno de evaluación que permita medir la precisión del modelo.

Predicción de enlaces en arranque en frío mediante la integración de información comunitaria con factorización de matrices no negativas

El artículo científico de [Minghu Tang y Wenjun Wang \(2022\)](#), publicado en la revista especializada *Chaos, Solitons & Fractals*, se centra en los

desafíos presentes en las redes del mundo real, que suelen estar incompletamente observadas. Esta incompletitud conduce a una estructura semi-conectada que dificulta la aplicación de métodos de predicción de enlaces convencionales.

El objetivo principal de este trabajo es explorar cómo utilizar los atributos de los nodos para compensar la falta de información topológica en la red. Esto se logra mediante la aplicación de algoritmos de agrupamiento y de similitud de atributos.

En este contexto, se presenta el modelo ACCSLP, diseñado específicamente para abordar el desafío de predecir conexiones en redes con múltiples nodos aislados. Este modelo se basa en el algoritmo de factorización de matrices no negativas y utiliza una matriz de adyacencia de la red, una matriz de pertenencia a la comunidad y una matriz de similitud de atributos como fuentes de información para generar predicciones sobre la estructura de la red.

Los resultados obtenidos en este estudio proporcionan una perspectiva sobre cómo mitigar el problema del arranque en frío. Dado que inicialmente nuestro sistema carece de información para realizar predicciones, el enfoque propuesto en el artículo permite aprovechar al máximo la información disponible para compensar la falta de información topológica en la red. Por esta razón, se ha elegido este modelo como base para el desarrollo del sistema de recomendación.

Bases Teóricas

Seguidamente se examinan los fundamentos teóricos que guían a los investigadores en estas áreas, con el objetivo de adquirir el conocimiento

esencial para la creación del sistema propuesto. Esta acción contribuye a enriquecer el proceso de investigación.

Sistemas de recomendación (SR)

De acuerdo a [Isinkaye, Folajimi, y Ojokoh \(2015\)](#), los sistemas de recomendación abordan el problema de la sobrecarga de información a la que los usuarios suelen enfrentarse al brindarles recomendaciones personalizadas y exclusivas de contenido y servicios, adaptadas a sus necesidades y preferencias. También, estas soluciones ayudan a los usuarios a descubrir lo que realmente les interesa entre la avalancha de información disponible, ofreciendo sugerencias a medida que se ajustan a sus gustos y requisitos únicos.

Tipos de sistemas de recomendación

Según la literatura, existen tres tipos de sistemas de recomendación, cada uno con un enfoque distinto.

Recomendadores basados en contenido

De acuerdo a [Aggarwal \(2016\)](#), los sistemas de recomendación basados en contenido utilizan las características descriptivas de los productos para generar sugerencias. Estos enfoques correlacionan las calificaciones y los perfiles de los usuarios con la información de los productos, con el fin de generar recomendaciones personalizadas. Sin embargo, [Martínez \(2022\)](#) señala que, aunque este método ofrece ventajas, como mitigar el problema de dispersión de datos, también presenta desventajas importantes, como su elevado costo computacional y la dificultad para generar recomendaciones a

usuarios nuevos o con perfiles incompletos. Además, no considera la evolución de las preferencias de los usuarios.

Recomendadores basados en conocimiento

Los sistemas basados en el conocimiento se fundamentan en conjuntos de reglas definidos por el usuario para limitar las posibles soluciones de recomendación. Esto otorga al usuario la capacidad de personalizar qué productos le gustaría recibir como sugerencias ([Martínez 2022](#)). Este enfoque resuelve con éxito el problema del *cold start* y no se ve afectado por la dispersión de datos. Además, aborda el desafío de la "cola larga" (*long tail*, en inglés), que se refiere a la tendencia de algunos sistemas a ofrecer repetidamente las mismas sugerencias. Sin embargo, al igual que los sistemas basados en contenido, enfrenta limitaciones en la variabilidad de las recomendaciones y el problema del conjunto vacío, que ocurre cuando no hay productos que coincidan con las preferencias del usuario.

Recomendadores basados en filtrado colaborativo

Este enfoque para generar recomendaciones se basa en la interacción de los usuarios con los productos, según [Aggarwal \(2016\)](#), los modelos de filtrado colaborativo utilizan el poder colaborativo de las calificaciones proporcionadas por múltiples usuarios para hacer recomendaciones. El principal desafío en el diseño de métodos de filtrado colaborativo es que las matrices de calificaciones subyacentes son dispersas. Es decir, que la matriz de ratings de los usuarios con los productos en su mayoría está compuesta de entradas vacías o no contienen información relevante.

Sistemas de recomendación basados en grafos

Estos sistemas de recomendación utilizan grafos como estructura para modelar usuarios, elementos, o ambos como nodos. A partir de esta este último se desarrollan varios algoritmos para generar recomendaciones ([Aggarwal, 2016](#)).

Grafos usuario – ítem

Es un grafo no dirigido y bipartito, $G = (N_u \cup N_i, A)$ que se compone de dos conjuntos de nodos, N_u representa a los usuarios, y N_i representa a los ítems o productos. Las conexiones entre estos nodos existen solo cuando un usuario ha calificado un ítem, lo que implica que el número de aristas corresponde al total de calificaciones observadas. Este tipo de grafo permite capturar eficazmente las interacciones entre usuarios y productos ([Aggarwal, 2016](#)).

Grafos usuario – usuario

Es un grafo no dirigido y bipartito, $G = (N_u, I)$ que se compone de un conjunto de nodos usuario N_u . Sea I_u el conjunto de elementos que el usuario u ha calificado, y I_v el conjunto de elementos que el usuario v ha calificado. La existencia de una arista entre ambos nodos se define en función de que ambos usuarios hayan calificado elementos similares ([Aggarwal, 2016](#)).

Grafos ítem – ítem

Un grafo ítem-ítem también llamado grafo de correlación $G = (N, A)$ es una red ponderada y dirigida en la que cada nodo de N representa un ítem, y cada arista de A se crea si al menos un usuario ha calificado un par de elementos. Las aristas tienen pesos asociados w_{ij} que indican la relación entre los ítems. La red es asimétrica, ya que el peso de una arista entre dos ítems no es necesariamente igual en ambas direcciones ([Aggarwal, 2016](#)).

En la presente investigación, se ha optado por utilizar este tipo de grafo para representar los productos; sin embargo, se utilizó una red no dirigida y simétrica, en la cual el peso de los enlaces entre dos elementos adyacentes es el mismo, es decir, $w_{ij} = w_{ji}$.

Técnicas de predicción de enlaces

De acuerdo a [Martínez \(2022\)](#) las técnicas de predicción de enlaces (*link prediction techniques*, en inglés) son “un conjunto de métodos del campo del análisis de las redes sociales que sirven para predecir nuevos enlaces que se van a formar en un grafo o para determinar enlaces que se han perdido” (p.39). Estas técnicas son especialmente relevantes debido a la naturaleza dinámica de los grafos, donde las relaciones y entidades pueden surgir o desaparecer con el tiempo. Entre las aplicaciones de la predicción de enlaces se encuentra la generación de recomendaciones, que se implementan sobre grafos que contienen información sobre las preferencias o el contenido generado por los usuarios.

Métodos de agregación para recomendadores basados en grafos

Los modelos de recomendación basados en grafos necesitan un método de agregación para combinar la similitud de aquellos productos que se repitan en la lista de recomendación $gsim_t$. Donde $gsim_t = \{(n_j, s_j), (n_k, s_k), \dots\}$, corresponde a la unión de los valores de similitud de los elementos.




Figura 1. Proceso de recomendación llevado a cabo con el grafo de interacción. Fuente: [Martínez \(2022\)](#)

De esta manera, se parte de un estado inicial donde se tienen los conjuntos $sim_t(n_x)$ de productos a recomendar con sus valores de similitud asociados. El siguiente algoritmo propuesto por [Martínez \(2022\)](#) establece una lista de recomendación R' para un modelo de grafos basados en productos, esta lista contiene una única aparición por cada producto similar, con un valor de similitud asociado, además, R' está ordenada de manera decreciente de acuerdo al valor de agregación. Entre los elementos que intervienen en el

algoritmo se encuentran, $I_t^+ \subset I$, el cual representa el conjunto de los productos con los que el usuario u_t ha interactuado previamente. Por el contrario, $I_t^- = I \setminus I_t^+$ es el conjunto de productos con los que el usuario u_t aún no ha interactuado.

$$\begin{aligned}
 R' = & \{ (i_j, ag_j), (i_k, ag_k), \dots \mid ag_j \geq ag_k \} \text{ donde } \forall (i_x, ag_x) \in R' \\
 & : \{ (i_x, s_{rx}), (i_x, s_{mx}), \dots, (i_x, s_{zx}) \} \in gsim_t \\
 & i_x \in I_t^- \\
 & i_r, i_m, \dots, i_z \in I_t^+ \\
 & ag_x = Aggr(\{s_{rx}, s_{mx}, \dots, s_{zx}\})
 \end{aligned}$$

A continuación, se presentan los métodos de agregación utilizados para obtener los valores de similitud para cada elemento del grafo.

- Máxima similitud (*Highest Similarity*, en inglés, HS): este método considera que el valor de agregación para un producto i_x , es el mayor valor de similitud s_x que tiene i_x en todas sus apariciones en la lista $gsim_t$.

$$Aggr() = HS(gsim_t) = \max(s_x)$$

- Votación simple (*Simple voting*, en inglés, SV): este método considera como valor ag_x el número de veces que i_x aparece en la lista de elementos $gsim_t$.

$$Aggr() = SV(gsim_t) = \text{count}(i_x)$$

- Votación ponderada (*Weighted voting*, en inglés, WV): el valor de agregación ag_x es la suma ponderada de los valores de similitud del producto i_x en la lista $gsim_t$. Donde s_j es cada valor de similitud asociado con un producto $i_x \in gsim_t$

$$Aggr() = WV(gsim_t) = \sum \frac{s_x}{\sum s_j}$$

- Votación posicional (*Positional voting*, en inglés, PV): para aplicar este método, la lista $gsim_t$ debe estar ordenada de manera decreciente. De este modo, el valor de similitud agregado ag_x dependerá de la posición

de i_x en dicha lista. La función $pos(i_x)$ devuelve la posición de i_x en $gsim_t$, comenzando desde 1.

$$Aggr() = PV(sort(gsim_t)) = \frac{1}{\sum pos(i_x)}$$

Para el desarrollo del sistema de recomendación utilizó el método de votación ponderada para obtener el valor de similitud de cada uno de los elementos i_x .

Aprendizaje automático

Aprendizaje Automático (*Machine Learning*, ML, en inglés) es un sub - campo de la inteligencia artificial que abarca un conjunto de algoritmos para ser aplicados en conjuntos de datos para resolver problemas de predicción (regresión), clasificación, y agrupación ([Athey, 2019](#)).

Estás técnicas de ML se pueden clasificar en tres tipos: supervisados, no supervisados y semi-supervisados, cada uno tiene una función y uso diferente de acuerdo al tipo de datos con el que se trabaja y el objetivo de la investigación o análisis que se está realizando. Para el presente estudio se utilizó técnicas de aprendizaje automático no supervisado, cuyo enfoque se centra en identificar agrupaciones de observaciones que comparten similitudes en sus características ([Athey, 2019](#)).

Render

Render es una plataforma de infraestructura en la nube que permite desplegar aplicaciones de distintos tamaños, esta ofrece varios servicios de acuerdo a las necesidades de los proyectos, su enfoque está en la

accesibilidad, fiabilidad y el tiempo de actividad ([Render, s/f](#)). Entre los servicios que ofrece Render se encuentran.

- **Servicios web:** permite el despliegue de aplicaciones web de manera sencilla y escalable.
- **Servicios privados:** admite la ejecución de servicios internos que solo son accesibles desde otros servicios de la plataforma, tales como como bases de datos o APIs internas.
- **Procesos en segundo plano:** permite ejecutar tareas en segundo plano que no necesitan interacción directa con los usuarios o respuesta inmediata.
- **Cron Jobs:** permite programar tareas automáticas que se ejecutan en intervalos específicos.
- **Almacenamiento de datos:** permite el uso de discos persistentes que aseguran la conservación de los datos de las aplicaciones durante los red despliegues.
- **Bases de datos:** da acceso a PostgreSQL como una base de datos completamente gestionada.

En esta investigación se emplearon los servicios de Render para respaldar el sistema de recomendación. En particular, se utilizó el servicio de cron jobs para programar la ejecución del sistema cada 10 minutos, el servicio de PostgreSQL para almacenar información sobre productos, usuarios, interacciones y listas de recomendación, y el servicio web para desplegar la plataforma de e-commerce que proporciona soporte de datos al sistema de recomendación.

Rango intercuartílico (RIC)

El Rango Intercuartílico (RIC) es una medida de dispersión que se utiliza para evaluar la variabilidad en la distribución central de un conjunto de datos. Específicamente, el IQR mide la dispersión del 50% central de los datos, ofreciendo una perspectiva sobre cómo se distribuyen los valores alrededor de la mediana, sin verse influenciado por los valores extremos [\(Bhandari, 2022\)](#). Para realizar el cálculo del RIC se considera tres elementos importantes.

- **Primer Cuartil (Q_1):** Determina el valor por debajo del cual se encuentra el 25% inferior de los datos ordenados.
- **Tercer Cuartil (Q_3):** Identifica el valor por debajo del cual se encuentra el 75% de los datos ordenados.
- **Cálculo del IQR:** Se obtiene restando Q_1 de Q_3 , $IQR = Q_3 - Q_1$.




Figura 2. Rango Intercuartílico. Fuente [Bhandari \(2022\)](#).

Además, con el cálculo del RIC es posible calcular el límite inferior y superior de la distribución de datos, mediante la implementación de las siguientes formulas

$$\text{Límite superior} = Q_3 + 1.5 \times RIC$$

$$\text{Límite inferior} = Q_1 - 1.5 \times RIC$$

K – means

K – means es un algoritmo de agrupamiento que pertenece a las técnicas de aprendizaje no supervisado, donde cada punto de dato pertenece estrictamente a un grupo. Este último maneja k centroides que utiliza para definir los grupos. Se considera que un punto está en un grupo particular si está más cerca del centroide de ese grupo que de cualquier otro ([Piech, 2012](#)). El algoritmo consiste en los siguientes pasos.

1. Inicializar los centroides de los clusters aleatoriamente $\mu_1, \mu_2, \dots, \mu_k \in R^n$
2. Repetir hasta alcanzar la convergencia
 - a. Para cada i , establecer la distancia euclídeana

$$c^{(i)} := \arg \min_j |x^{(i)} - \mu_j|^2$$

- b. Para cada j , establecer.

$$\mu_j := \frac{\sum_{i=1}^m \{c^{(i)} = j\} x^{(i)}}{\sum_{i=1}^m \{c^{(i)} = j\}}$$




Figura 3. Agrupación de puntos de datos utilizando el algoritmo K-means.
Fuente: [Piech \(2012\)](#)

Kernel

De acuerdo con [Bernstein \(2017\)](#) un kernel es una función de la forma $k(x, x') = \langle \psi(x), \psi(x') \rangle$ donde ψ es una función que proyecta un vector x en un nuevo espacio. La función de kernel calcula el producto punto entre dos vectores proyectados.

Los kernels son utilizados como medidas de similitud entre objetos, donde cada objeto es representado como un vector. Por ejemplo, sea a , b , y c , tres objetos entonces $s(a, b) > s(a, c)$ si los objetos a y b son considerados más similares que los objetos a y c . ([scikit-learn, s/f](#)). Algunas de las medidas que son usadas para determinar la similitud entre dos vectores son las siguientes.

- Kernel lineal: Es un caso especial del kernel polinomial, donde el grado es 1

$$k(x, y) = x^T y$$

- Kernel polinomial: Esta función calcula el kernel del polinomio de grado d , entre dos vectores. No solo toma en cuenta vectores en la misma dimensión, sino también a través de más dimensiones.

$$k(x, y) = (\gamma x^T y + c_0)^d$$

- Kernel función de base radial (*Radial basis function*, en inglés, RBF): Esta función hace énfasis en el parámetro γ que establece la dispersión del kernel. Sea $\gamma > 0$, mientras mas grande sea el valor de γ este hará que $-\gamma |x - y|^2$ tenga un valor más grande ([Bernstein, 2017](#)).

$$k(x, y) = e^{-\gamma |x-y|^2}$$

- Similitud de coseno: Mide la similitud entre dos vectores dentro de un mismo espacio vectorial calculando el coseno del ángulo que los separa. Un valor de coseno igual a 0 indica que los vectores son ortogonales y no tienen similitud alguna. En cambio, un valor cercano a 1 significa que el ángulo entre los vectores es próximo a 0, lo que sugiere una mayor coincidencia entre ellos. La función de similitud se expresa de la siguiente manera:

$$sim(x, y) = \frac{x \cdot y}{\|x\| \|y\|}$$

De acuerdo con las medidas presentadas anteriormente, se utilizó la función de base radial (RBF) como medida de similitud de vectores para los elementos que conforman el grafo.

Factorización de matrices no negativas

La factorización de matrices no negativas (*Non-negative matrix factorization*, en inglés, NMF) es una técnica utilizada para descomponer una

matriz no negativa $X \in R^{m \times n}$ en dos matrices no negativas $U \in R^{m \times k}$ y $V \in R^{n \times k}$, donde k es el rango de factorización $k < \min(m, n)$. Por lo tanto, el objetivo es encontrar una matriz $X' = UV^T$ que se aproxime a X utilizando el producto de dos matrices.

Según [Gan, Liu, Li, y Zhang \(2021\)](#), “en el contexto de los sistemas de recomendación el problema de los datos incompletos se puede abordar procesando los datos históricos de los usuarios mediante el uso de la técnica de NMF” (p.1081). Esto significa que, al aplicar NMF, el sistema de recomendación puede generar sugerencias relevantes, incluso cuando los datos de entrada son dispersos o están incompletos.

Métodos de optimización

Estos son algoritmos utilizados para minimizar el error de reconstrucción entre la matriz original X y el producto de dos matrices no negativas U y V^T . A continuación, se muestran algunos de los métodos de factorización.

- Método de actualización multiplicativa: Este método consiste en realizar iteraciones donde en cada iteración actualiza las matrices U y V^T . Con este método se garantiza la no negatividad de la matriz de menor rango durante cada iteración. Sin embargo, no garantiza alcanzar un mínimo local ni una solución completamente estable ([Gan et al., 2021](#)).

$$u_{ik} \leftarrow u_{ik} \frac{\sum_j (x_{ij} v_{jk})}{\sum_j v_{jk}} \quad v_{jk} \leftarrow v_{jk} \frac{\sum_i (x_{ij} u_{ik})}{\sum_i u_{ik}}$$

- Método alternado de mínimos cuadrados no negativos: De acuerdo con [Gan et al. \(2021\)](#), es una técnica que divide el problema en dos subproblemas de optimización. Cada uno se resuelve

alternadamente. Esta técnica ofrece una mayor capacidad de optimización y puede converger a un punto estable. No obstante, este enfoque requiere una alta complejidad computacional.

$$V^{t+1} := \arg \min_V \|X - UV^T\|_F^2 \quad U^{t+1} := \arg \min_U \|X - UV^{t+1}\|_F^2$$

Función de pérdida

De acuerdo a [Tang y Wang \(2022\)](#), dada una función objetivo $O = \min_{U \geq 0, V \geq 0} L(X, UV^T)$, $L(*,*)$ es la función de pérdida que mide la diferencia o el error entre la matriz original X y el producto de las dos matrices no negativas U y V^T . A continuación, se muestran algunas de funciones de pérdida.

- Función de divergencia generalizada Kullback-Leibler (KL):

$$L = D(X||UV^T) = \sum_{i,j} (x_{ij} \log \frac{x_{ij}}{(UV^T)_{ij}} - x_{ij} + (UV^T)_{ij})$$

- Distancia Euclidiana:

$$L = \|X - UV^T\|^2 = \sum_{i,j} (x_{ij} - (UV^T)_{ij})^2$$

En la presente investigación implementó la función de divergencia generalizada Kullback-Leibler para determinar el error entre la matriz original y la aproximada.

Modelo de predicción de enlaces ACCSLP

Esta técnica de predicción de enlaces, propuesta por [Tang y Wang \(2022\)](#), se centra en abordar el problema del *cold start* utilizando los atributos de los nodos de una red dispersa para predecir enlaces dentro de la misma.

Su enfoque combina tanto la información topológica de la red como las características de los nodos que la componen.

De acuerdo con lo anterior, el modelo utiliza la información de la matriz de adyacencia $S_{n \times n}$ de la red. Debido a que esta matriz es dispersa, se complementa con la matriz de similitud de atributos $Z_{n \times n}$, y la matriz de pertenencia a una comunidad $X_{n \times n}$ que sirven como fuente de información para mitigar la dispersión.

Para descomponer e integrar la información de estas matrices se utiliza la técnica de factorización de matrices no negativas. Así, la matriz de adyacencia se descompone como $S \approx UH$, donde $U = [u_{n,k}] \in R_+^{n \times k}$ y $H = [h_{k,n}] \in R_+^{k \times n}$; la matriz de pertenencia a una comunidad se descompone como $X \approx WH$, donde $W = [w_{n,k}] \in R_+^{n \times k}$ y $H = [h_{k,n}] \in R_+^{k \times n}$; mientras que la matriz de similitud de atributos $Z_{n \times n}$ se descompone como $Z \approx UV$, donde $U = [u_{n,k}] \in R_+^{n \times k}$ y $V = [v_{k,n}] \in R_+^{k \times n}$.




Figura 4. Esquema del modelo ACCSLP. Fuente: [Tang y Wang \(2022\)](#)

Función de pérdida

La función de pérdida propuesta para el algoritmo de NMF utilizado en este modelo, es la función de divergencia generalizada Kullback-Leibler (KL), Esta incorpora los factores de regularización α y β para controlar la influencia de las matrices complementarias, y se define de la siguiente manera:

$$\begin{aligned}
 O &= D(S | U, H) + \alpha D(X | W, H) + \beta D(Z | U, V) \\
 O &\cong \sum_{l=1}^n \sum_{j=1}^n (S_{lj} - s_{lj} \log \sum_{k=1}^K u_{lk} h_{kj}) \\
 &\quad + \alpha \sum_{i=1}^n \sum_{j=1}^n (X_{ij} - \log \sum_{k=1}^K w_{ik} h_{kj}) \\
 &\quad + \beta \sum_{l=1}^n \sum_{m=1}^n (Z_{lm} - z_{lm} \log \sum_{k=1}^K u_{lk} v_{km})
 \end{aligned}$$

Reglas de actualización multiplicativa (MU)

Con el fin de lograr la divergencia de la función objetivo, se utiliza las reglas de actualización multiplicativas, las cuales fueron obtenidas luego de derivar parcialmente la función O con respecto a cada una de las variables factor W, H, U, V . Estas son las siguientes:

$$u_{lk} \leftarrow u_{lk} \frac{\sum_{j=1}^n \frac{S_{lj}}{S_{lj}} h_{kj} + \beta \sum_{m=1}^n \frac{Z_{lm}}{Z_{lm}} v_{km}}{\sum_{j=1}^n h_{kj} + \beta \sum_{m=1}^n v_{km}}$$

$$h_{kj} \leftarrow h_{kj} \frac{\sum_{l=1}^n \frac{S_{lj}}{S_{lj}} u_{lk} + \alpha \sum_{i=1}^n \frac{x_{ij}}{X_{ij}} w_{ik}}{\sum_{l=1}^n u_{lk} + \alpha \sum_{i=1}^n w_{ik}}$$

$$w_{ik} \leftarrow w_{ik} \frac{\sum_{i=1}^n \frac{x_{ij}}{X_{ij}} h_{kj}}{\sum_{j=1}^n h_{kj}}$$

$$v_{km} \leftarrow v_{km} \frac{\sum_{m=1}^n \frac{Z_{lm}}{Z_{lm}} u_{lk}}{\sum_{l=1}^n u_{lk}}$$

K fold target encoding

Según [Ayria \(2019\)](#) la codificación del objetivo con validación cruzada en k particiones (*K-fold target encoding*, en inglés) es una técnica de aprendizaje automático para transformar variables categóricas en numéricas. Esta estrategia consiste en dividir los datos en k subconjuntos y, en lugar de calcular la media del objetivo utilizando todo el conjunto de datos, se calcula para cada categoría basándose únicamente en la media de las otras particiones.

Cuando el valor objetivo es una variable continua se utiliza la siguiente ecuación para obtener el promedio por cada partición. En esta S_i es la

codificación para la categoría i , n_i es el número de observaciones con categoría i , L_i es el conjunto de observaciones con categoría i , y n es el número de observaciones.

$$S_i = \lambda_i \frac{\sum_{k \in L_i} Y_k}{n_i} + (1 - \lambda_i) \frac{\sum_{k=1}^n Y_k}{n}$$

El factor de disminución λ_i para la categoría i esta dado por la siguiente ecuación, donde m es un factor de suavizado. Cuando m toma valores grandes, la función da más peso en el promedio global. Este último es calculado utilizando una estimación empírica Bayes, la cual define σ_i^2 como la varianza de y con categoría i , y τ^2 es la varianza global de y .

$$\lambda_i = \frac{n_i}{m + n_i} \quad m = \frac{\sigma_i^2}{\tau^2}$$

Métricas de evaluación de técnicas de predicción de enlace

Las métricas de evaluación permiten evaluar el rendimiento predictivo de los algoritmos en el dominio de predicción de enlaces. Estas métricas se basan en los verdaderos positivos (VP), estos son elementos relevantes para el usuario objetivo dentro de la lista de recomendación R obtenida por el sistema de recomendación. En otras palabras, los VP son los elementos que le han gustado al usuario o con los que ha interactuado en el conjunto de evaluación, y que fueron recomendados por el sistema [\(Martínez, 2022\)](#). A continuación, se detallan algunas métricas de evaluación utilizadas en este trabajo.

Área bajo la curva característica de funcionamiento del receptor (AUC-ROC)

Esta métrica permite determinar el rendimiento general del algoritmo de predicción. El índice AUC puede ser interpretado como “la probabilidad de que el puntaje de un enlace seleccionado aleatoriamente del conjunto de prueba sea mayor que un enlace seleccionado aleatoriamente del conjunto de enlaces no existentes” ([Tang y Wang, 2022, p.7](#)). Por lo tanto, sea x es el número de comparaciones independientes, seleccionamos aleatoriamente un enlace faltante y uno no existente para comparar sus puntajes, donde x' veces el enlace faltante tiene un puntaje mayor y x'' veces ambos enlaces tienen el mismo puntaje entonces, el índice AUC es definido de la siguiente forma:

$$AUC = \frac{x' + 0.5 x''}{x}$$

En relación con lo anterior, [Wang, Ma, y Yuan \(2020\)](#) exponen lo siguiente:

Si todos los puntajes son generados a partir de una distribución independiente e idéntica, la precisión debería ser aproximadamente 0.5. Por lo tanto, el grado en que la precisión excede 0.5 indica cuánto mejor se desempeña el algoritmo en comparación con el puro azar. (p.8)

Esto implica que un valor de precisión superior a 0.5 sugiere que el modelo tiene capacidad para hacer predicciones más efectivas que las que se lograrían al adivinar aleatoriamente, lo que se convierte en una métrica clave para evaluar su rendimiento.

Precision@k

Esta medida indica cuántos productos relevantes para un usuario específico se encuentran dentro de la lista de productos recomendados. El parámetro k se refiere al tamaño de la lista de recomendación ([Martínez, 2022](#)). La precisión se determina mediante el siguiente cálculo:

$$P@k = \frac{|TP|}{k}$$

Donde $|TP|$ es el número de elementos relevantes recuperado, es decir, los productos con los que ha interactuado el usuario previamente y forman parte de la lista de recomendación, y k es el tamaño de la lista de recomendación.

Descomposición en valores singulares (SVD)

Según [Brunton y Kutz \(2017\)](#), la Descomposición en valores singulares (Singular value decomposition, en inglés, SVD) es una técnica para descomponer cualquier matriz compleja X de tamaño $n \times m$. En esta descomposición, las matrices U y V son ortogonales, mientras que la matriz Σ es diagonal y contiene los valores singulares de X , ordenados de forma decreciente .

De acuerdo con los mismos autores, los primeros r valores singulares definen el peso de las columnas de la matriz U , lo que permite reducir su dimensión tomando solo las primeras r columnas y valores de Σ , obteniendo una representación más compacta. Según el teorema de Eckart-Young, la mejor aproximación de menor rango a la matriz X , en términos de mínimos cuadrados, se logra truncando su descomposición en valores singulares hasta el rango r . La aproximación $\hat{X}$ se forma con las primeras r columnas de U y V ,

junto con un sub-bloque principal de Σ . De tal manera que la aproximación de X queda expresada como $\hat{X} \approx \hat{\Sigma} \tilde{V}^T$.

Cron job

Un *Cron job* es una tarea programada que se ejecuta automáticamente en momentos específicos en sistemas Unix y Linux. La sintaxis de cron se compone de cinco campos que especifican cuándo ejecutar una tarea: minuto (0-59), hora (0-23), día del mes (1-31), mes (1-12) y día de la semana (0-7, donde 0 y 7 representan el domingo). Además, cron admite el uso de caracteres especiales: el asterisco (*) para indicar "cualquier valor", la barra inclinada (/) para definir intervalos, el guion (-) para establecer rangos, y la coma (,) para enumerar múltiples valores ([Cortes, 2023](#)).

Python

Es un lenguaje de programación multipropósito de scripting, el cual soporta programación orientada a objetos. Una de sus principales características, es su simplicidad que permite a los desarrolladores crear scripts sin conocimiento de terceras integraciones ([Mark, 2009](#)).

Pandas

Pandas es una herramienta de análisis y manipulación de datos de código abierto rápida, potente, flexible y fácil de usar, construida sobre el lenguaje de programación Python ([Pandas, s/f](#)). Podemos mencionar las siguientes ventajas de pandas:

- Estructuras de datos flexibles: Ofrece DataFrames y Series, que facilitan la manipulación y análisis de datos estructurados.
- Amplia funcionalidad: Proporciona herramientas para la limpieza, transformación y agregación de datos, lo que es fundamental en análisis de datos.

Scikit-learn

Scikit-learn es una biblioteca de Python que ofrece una amplia gama de herramientas para el aprendizaje automático, incluye algoritmos que se aplican en tareas como clasificación, regresión, agrupamiento, reducción de dimensionalidad, preprocesamiento de datos, entre otras ([scikit-learn Machine Learning in Python, s.f.](#)).

NumPy

NumPy es una biblioteca de Python que ofrece un objeto de matriz multidimensional y diversas rutinas para realizar operaciones con matrices. Estas operaciones incluyen cálculos matemáticos, manipulaciones lógicas, cambios de forma, ordenación, selección, entrada/salida (E/S), transformadas discretas de Fourier, álgebra lineal básica, operaciones estadísticas fundamentales y simulación aleatoria, entre otros ([Numpy, s/f](#)).

PostgreSQL

PostgreSQL es un sistema de gestión de bases de datos objeto-relacional de código abierto que es compatible tanto con sistemas operativos

basados en Unix como con Windows. Se destaca por satisfacer las necesidades de la mayoría de sus usuarios y por su uso en sistemas críticos que manejan altas cargas de trabajo ([Luzanov, Rogov, y Levshin, 2023](#)).

Metodología

En el desarrollo de sistemas, es esencial seguir un estándar que garantice el cumplimiento en todas las etapas, desde la definición de requerimientos hasta las pruebas finales. Existen diversas metodologías que ofrecen enfoques y procesos estructurados para la creación de productos tecnológicos.

En relación con lo anterior, la metodología clásica o modelo en cascada, implica que cada fase está claramente definida con sus propias etapas y actividades específicas que deben cumplirse antes de avanzar a la siguiente fase ([Pressman, 2010](#)).

De acuerdo a este enfoque, [Sommerville \(2016\)](#) identifica las fases secuenciales que componen este modelo:

1. Análisis y definición de requisitos: Se documentan los requisitos del sistema para comprender qué debe hacer el software y cumplir con las necesidades del cliente.
2. Diseño del sistema y del software: Se define la arquitectura y los componentes del software, así como las interfaces entre ellos para cumplir con los requisitos.
3. Implementación y pruebas: Se escribe y prueba el código del software para asegurar que cumpla con los requisitos establecidos.
4. Integración y pruebas: Se identifican y corrigen errores mediante pruebas para evaluar la calidad del software.

5. Funcionamiento y mantenimiento: Se realiza el mantenimiento del software después de la entrega para corregir errores, agregar nuevas funcionalidades y mejorar el rendimiento.




Figura 5. Modelo en cascada. Fuente: [Sommerville \(2016\)](#)

En la misma dirección, Scrum es un marco ágil de gestión de proyectos que optimiza el tiempo y los recursos mediante ciclos cortos de desarrollo llamados *sprints*, que duran entre 2 y 4 semanas. Se centra en la entrega continua y la adaptabilidad, con el equipo trabajando de forma autónoma en elementos prioritarios del *backlog* del producto. La participación activa del propietario del producto y la autoorganización del equipo son esenciales, y las reuniones diarias permiten revisar el progreso y resolver problemas de manera colaborativa ([Sommerville, 2016](#)).

Por otro lado, la metodología de desarrollo conocida como Proceso estándar de la industria cruzada para minería de datos (*Cross Industry Standard Process for Data Mining*, en inglés, CRISP-DM) establece las bases para proyectos definidos en el área de la ciencia de datos. De acuerdo con [Hotz \(2018\)](#) esta metodología consta de seis fases:

1. Comprensión del negocio: Se analiza la lógica del negocio, los objetivos, los recursos, y los indicadores de éxito desde el punto de vista de la ciencia de datos.
2. Entendimiento de los datos: Se recolecta y describe los tipos de datos, también se debe explicar las relaciones entre ellos y verificar su calidad.
3. Preparación de los datos: Se elige y documenta el conjunto de datos, para luego limpiarlos, estandarizarlos y si es necesario se calculan datos derivados.
4. Modelado: Se debe determinar los algoritmos a utilizar, luego se separa la información en conjuntos de entrenamiento, prueba y validación, y por último, se construye y compara el modelo con otras alternativas.
5. Evaluación: Se revisa los modelos propuestos para verificar que se adapten a los objetivos del negocio, luego se debe aprobar el modelo que mejor se adapte, y si es necesario se realizan correcciones.
6. Despliegue: Se planifica el despliegue para que los clientes accedan a los resultados, posteriormente se establece un plan de monitoreo y mantenimiento, para finalmente producir un reporte final y realizar una evaluación del proyecto para identificar mejoras futuras.

Se ha elegido la metodología CRISP-DM para el desarrollo del sistema de recomendación, dado que esta metodología se adapta perfectamente a los procesos específicos que se llevarán a cabo, incluyendo el preprocesamiento de datos, el desarrollo de modelos y la recolección de información. CRISP-DM proporciona un marco estructurado que asegura el cumplimiento riguroso de cada una de sus fases, lo que resulta fundamental para garantizar la calidad y eficacia del sistema propuesto.

Estilo de arquitectura del sistema

Los sistemas basados en ML enfrentan retos específicos como la selección de datos, algoritmos y modelos. Además, requiere de nuevas prácticas estandarizadas para integrarlos con los sistemas de software ([Muccini y Vaidhyanathan, 2021](#)). Por esta razón, han surgido arquitecturas para sistemas basados en ML.

El autor [Yokoyama \(2019\)](#) presentó el patrón de arquitectura Separación de la lógica de negocio de los modelos de ML el cual está estructurado en tres capas. Esta arquitectura tiene como objetivo separar el proceso inferencia y preprocesamiento de los datos, de la lógica de negocio. De tal manera que evita el acoplamiento entre los componentes de los subsistemas de ML y de software.

- Procesamiento de los datos: Transforma la data sin procesar en características para el análisis y uso en técnicas de ML.
- Motor de inferencia: Proceso de inferencia que se aplica sobre la data procesada.

En este contexto, la arquitectura *Gateway-Routing* presenta una estructura similar a la descrita anteriormente. Desacopla la lógica de negocio, el proceso de inferencia y el procesamiento de datos al implementarlos como servicios independientes. Sin embargo, introduce una capa adicional de complejidad entre la interfaz de usuario y la lógica del negocio, lo que puede resultar en una alta latencia del sistema ([Yokoyama, 2019](#)). Esta arquitectura aborda el problema que surge cuando hay múltiples servicios, al incorporar una capa adicional llamada *Gateway*, que se encarga de enrutar las solicitudes a las instancias adecuadas ([Washizaki et al., 2022](#)).




Figura 7. Patrón de arquitectura Gateway-Routing. Fuente: [Yokoyama \(2019\)](#)

Por último, la arquitectura Lambda para ML tiene como objetivo soportar el despliegue de aplicaciones basadas en ML que responden a las solicitudes de los usuarios en tiempo real. Este patrón de diseño aborda el problema de

la velocidad de predicción utilizando la arquitectura Lambda, la cual emplea las capas de velocidad y de lote. En este contexto, se utilizan dos modelos de ML distintos en cada capa. La capa de velocidad se enfoca en procesar datos en tiempo real, manejando pequeñas cantidades de datos de entrada y priorizando la rapidez. Por otro lado, el modelo de ML en la capa de lotes procesa grandes volúmenes de datos, lo que permite obtener un conocimiento más profundo y alcanzar un mayor nivel de precisión. ([Runpakprakun et al., 2021](#)).




Figura 8. Arquitectura Lambda para ML. Fuente: [Runpakprakun et al. \(2021\)](#)

Para el desarrollo del sistema de recomendación, se ha optado por utilizar la arquitectura de Separación de la Lógica de Negocio de los Modelos de ML. Esta arquitectura es adecuada porque permite dividir de manera clara

las tareas entre la lógica de negocio y los procesos de ML. Al hacerlo, facilita la independencia de cada componente, como la inferencia y el procesamiento de datos, lo que asegura un flujo de datos más organizado dentro de la capa de ML. Además, esta separación contribuye a evitar el acoplamiento entre los subsistemas, promoviendo la escalabilidad y el mantenimiento del sistema.

CAPÍTULO III

MARCO METODOLÓGICO

Tipo de investigación

Tomando en cuenta el objeto de estudio, la presente investigación es del tipo aplicada, de acuerdo a [Castro, Gómez, y Camargo \(2022\)](#) la investigación aplicada utiliza los conocimientos adquiridos previamente en la investigación básica para enfocarlos en la solución de objetivos específicos. Por lo tanto, este tipo de investigación se basa en todo el conocimiento existente en un área concreta, que se utiliza para abordar problemas prácticos específicos.

De acuerdo a lo anterior, este trabajo de grado se considera una investigación aplicada dado a que tiene como objetivo aplicar el conocimiento en el área de sistemas de recomendación, y técnicas de predicción de enlaces para el desarrollo de un sistema de recomendación basado en grafos.

Diseño de la investigación

[Sabino \(1992\)](#) establece que el diseño de la investigación se centra en la planificación y ejecución de pruebas o experimentos con el fin de verificar si

las bases teóricas concuerdan con la realidad. En esta etapa, se hace énfasis en la atención a los detalles prácticos relacionados con la verificación de las ideas y la planificación de los experimentos.

El diseño de la investigación del presente trabajo de investigación es documental y de campo. La investigación documental “es un proceso basado en la búsqueda, recuperación, análisis, crítica e interpretación de datos secundarios, es decir, los obtenidos y registrados por otros investigadores” ([Arias, 2012, p.27](#)). La presente investigación será del tipo documental porque se basará en fuentes documentales e informes técnicos en su elaboración.

Además, según el mismo autor indica que la investigación de campo es aquella que consiste en la recolección de datos directamente de los sujetos investigados, o de la realidad donde ocurren los hechos (datos primarios), sin manipular o controlar variable alguna, es decir, el investigador obtiene la información, pero no altera las condiciones existentes. De allí su carácter de investigación no experimental. De acuerdo con esta definición, la presente investigación se adapta al diseño de campo, ya que busca utilizar la interacción de los usuarios con los productos del e-commerce como fuente de información.

Población y muestra

La población según Arnau (como se citó en [Hurtado de Barrera, 2010](#)) es “un conjunto de elementos o seres concordantes entre sí en cuanto a una serie de características, de los cuales se desea obtener alguna información” (p. 268). Adicionalmente, la misma autora define la muestra como “una porción de la población que se toma para realizar el estudio, y debe ser representativa (de la población)” (p.269).

En el contexto de esta investigación, se centra en una población finita compuesta por potenciales usuarios del sistema, que sean mayores de 18

años quienes hayan interactuado previamente con sistemas de e-commerce, residenciados en Venezuela. Para seleccionar la muestra, se empleará el muestreo no probabilístico, el cual se realiza sin conocer la probabilidad de inclusión de cada elemento de la población. En este tipo de muestreo, el investigador utilizará criterios establecidos por él mismo para la escogencia, lo que pudiera no garantizar la representatividad de la muestra. Sin embargo, en ocasiones pudiera ser adecuado si el enfoque está en la relevancia de los resultados más que en la representatividad ([Hurtado de Barrera, 2010](#)).

En este caso, se aplicará la técnica de muestreo casual, la cual consiste en definir el tamaño de la muestra y seleccionar los elementos sin criterios específicos, tomando los casos disponibles en ese momento. Mediante esta técnica, se invitará a un grupo seleccionado de usuarios a interactuar con el e-commerce. Posteriormente, se les pedirá que completen un cuestionario para evaluar la aceptabilidad de las recomendaciones proporcionadas por el sistema de recomendación. Este cuestionario incluirá preguntas diseñadas para recopilar datos cualitativos sobre la aceptación de las recomendaciones realizadas por el sistema. La información obtenida permitirá validar el funcionamiento del sistema propuesto.

Dado que la población de potenciales usuarios del sistema de recomendación es desconocida y no es posible especificar un número exacto de participantes, el tamaño de la muestra será seleccionado de manera subjetiva y flexible.

Técnica de Recolección de datos

Revisión documental

De acuerdo a [Hurtado de Barrera \(2010\)](#) la técnica de revisión documental “recurre a información escrita, ya sea bajo la forma de datos que pueden haber sido producto de observaciones o de mediciones hechas por otros, o como textos que en sí mismos constituyen las unidades de estudio” (p.771). Adicionalmente, esta técnica también abarca la revisión de otro tipo de documentos como videos, representaciones gráficas, fotografías y material digital. Esta técnica se utilizará para revisar la documentación relacionada con los sistemas de recomendación. El objetivo es comprender los procesos que determinan su comportamiento. Además, se revisarán trabajos de investigación centrados en sistemas de recomendación, como el estudio realizado por [Martínez \(2022\)](#), titulado “Sistemas de recomendación y explicaciones basados en grafos de interacción”.

Cuestionario

Según [Arias \(2012\)](#), el cuestionario “es la modalidad de encuesta que se realiza de forma escrita mediante un instrumento o formato en papel contentivo de una serie de preguntas. Se le denomina cuestionario autoadministrado porque debe ser llenado por el encuestado, sin intervención del encuestador” (p.74). Con esta técnica, se planteará un conjunto de preguntas cerradas a los entrevistados con el objetivo de medir y valorar la aceptabilidad de las recomendaciones realizadas por el sistema de recomendación.

Fases de la investigación

[Lozada \(2014\)](#) expone que la investigación aplicada consta de tres fases principales. En primer lugar, se realiza un proceso investigativo inicial que implica buscar aplicaciones prácticas y adaptar las teorías o resultados de las ciencias básicas. A continuación, se incorporan las necesidades sociales o industriales en el proceso, lo que conduce a la creación de conceptos de aplicación de la teoría. Por último, se lleva a cabo un proceso investigativo de maduración y transferencia de la tecnología, en el cual se crean prototipos que materializan los conceptos y se pueden transferir a la industria para convertirse en productos finales. Estas fases permiten que la investigación aplicada tenga un impacto directo en la práctica y facilite la transformación de ideas teóricas en soluciones tangibles y aplicables en el mundo real.

Dicho lo anterior, para cumplir con el objetivo general de este trabajo de investigación, se debe seguir una serie de fases acordes a los objetivos específicos planteados, que al mismo tiempo requieren de la ejecución de determinadas actividades para su consecución. De esta manera, se presentan las siguientes fases:

- 1. Analizar la teoría existente sobre sistemas de recomendación y técnicas de predicción de enlaces.**
 - 1.1. Revisar documentos, investigaciones, y artículos científicos.
 - 1.2. Adaptar las teorías y resultados de las ciencias básicas al proyecto de investigación.
- 2. Definir y analizar los requerimientos del sistema:**
 - 2.1. Determinar la metodología para el desarrollo del software.
 - 2.2. Definir los requerimientos del sistema de recomendación en base a los conceptos de aplicación de la teoría existente.
- 3. Diseñar el sistema, modelo arquitectónico, estructura de datos e Interfaces**

- 3.1. Establecer la arquitectura del sistema de recomendación.
- 3.2. Identificar los datos abstractos y sus relaciones.
- 4. Desarrollar el sistema de recomendación basado en técnicas de predicción de enlaces:**
 - 4.1. Procesar los datos utilizados por el sistema.
 - 4.2. Construir el sistema de recomendación.
- 5. Evaluar la precisión del sistema de recomendación**
 - 5.1. Evaluar la precisión del modelo.
 - 5.2. Evaluar la precisión de las listas de recomendación.
 - 5.3. Evaluar la aceptabilidad de las recomendaciones por los usuarios.

CAPÍTULO IV

ANÁLISIS, INTERPRETACIÓN Y PRESENTACIÓN DE LOS RESULTADOS

El presente capítulo especifica y describe todos los procesos para dar solución al desarrollo del sistema de recomendación.

Fase 1: Analizar la teoría existente sobre sistemas de recomendación y técnicas de predicción de enlaces

Se lleva a cabo una búsqueda exhaustiva y exploración de diversos estudios, investigaciones, proyectos y artículos científicos relacionados con el objeto de investigación. Entre ellos se incluyen proyectos como un sistema de recomendación y explicación basado en grafos de interacción, un sistema de recomendación basado en filtrado colaborativo para una tienda de comercio electrónico, y un modelo de predicción de enlaces diseñado para situaciones en las que las redes tienen una baja densidad de conexiones.

Estos trabajos se detallan en profundidad en los antecedentes presentados en el Capítulo II de este trabajo.

Revisar documentos, investigaciones, y artículos científicos

En esta sección se exponen los antecedentes que fundamentan esta investigación, clasificados según el tipo de documento, ya que se consideraron trabajos de investigación, tesis y artículos científicos. La [Tabla 1](#) muestra los diferentes tipos de sistemas de recomendación analizados en este estudio.

Tabla 1. Comparación de diferentes sistemas de recomendación

Tipo	Descripción	Técnicas utilizadas
Software	Sistema que utiliza las interacciones de los usuarios con los productos para generar las recomendaciones.	Se utilizan las técnicas de predicción de enlaces basadas en nodos vecinos, métodos de precisión, y métodos de ranking.
Software	Sistema que utiliza la similitud entre usuarios basándose en las compras realizadas por estos.	Se utiliza la técnica de filtrado colaborativo basada en usuarios, métodos de evaluación, y medidas de similitud de atributos.
Investigación	Modelo de sistema de predicción de enlaces para redes semi conectadas, donde hay presencia de muchos nodos aislados.	Se construye un marco de trabajo que utiliza matrices de adyacencia, medidas de similitud de atributos, algoritmos de agrupamiento, y factorización de matrices no negativas.

Adaptar las teorías y resultados de las ciencias básicas al proyecto de investigación.

En esta sección se detallan los elementos teóricos que se adaptaron para la construcción del sistema. La [Tabla 2](#) muestra las investigaciones que sirvieron como antecedentes, así como los elementos teóricos presentados por estas y cómo se aplicaron en la presente investigación.

Tabla 2. Adopción de los elementos teóricos en la investigación

Título del trabajo	Técnicas utilizadas	Descripción
Sistemas de recomendación y explicaciones basados en grafos de interacción (Martínez, 2022)	Grafos de interacción	La estructura del grafo es utilizada para representar las interacciones de los usuarios como enlaces, y los vértices como los ítems.
	Medida de precisión: <i>Precision@k</i>	Se utilizó para determinar el número de ítems recomendados que son relevantes para el usuario.
	Método de agregación: <i>Votación ponderada</i>	Es utilizado para darle un único valor de similitud a los ítems que han sido predichos por el sistema de recomendación.
Cold-start link prediction integrating community information via multi-nonnegative matrix factorization (Tang y Wang, 2022)	Medidas de similitud: RBF kernel	Esta técnica se utiliza para calcular la similitud entre ítems basándose en sus vectores de atributos. La similitud se determina por la distancia entre los dos vectores.
	Algoritmo de agrupamiento: K – means	Se utilizó para agrupar los ítems en grupos. Los ítems que comparten un mismo grupo poseen atributos similares.
	Matriz de adyacencia	Es la representación matricial del grafo de interacciones.
	Matriz de similitud de atributos	Es una matriz utilizada para representar la similitud entre los ítems.
	Matriz de pertenencia a una comunidad	Es una matriz construida a partir de las etiquetas del grupo al que pertenece cada ítem.
	NMF	Es utilizado para descomponer y fusionar las matrices de adyacencia, similitud de atributo y de pertenencia a una comunidad

Fase 2: Definir y analizar los requerimientos del sistema

En base a los conocimientos teóricos adquiridos, se va a identificar los requerimientos del sistema, así como la metodología que va a guiar el desarrollo del proyecto.

Metodología de desarrollo

En la base teórica presentada en el capítulo II, se evaluaron diversas metodologías de desarrollo, optando por CRISP-DM. Este modelo ofrece un enfoque estructurado que abarca desde la comprensión del problema hasta el despliegue del modelo. A continuación, se detallan las fases a implementar en el desarrollo del sistema de recomendación siguiendo los lineamientos de este modelo.

1. **Comprensión del negocio:** En esta fase, se definen las funciones y objetivos del sistema de recomendación mediante el análisis de documentos, artículos científicos e investigaciones. En el capítulo II se presentaron varios estudios que sirvieron como base para entender la lógica del sistema y establecer sus objetivos.
2. **Entendimiento de los datos:** Durante esta fase, se va a analizar las colecciones de datos disponibles junto con sus características.
3. **Preparación de los datos:** En esta fase, se seleccionan las colecciones de datos que se utilizarán para extraer información de las características relevantes. Para ello, se emplearán herramientas como el lenguaje de programación Python, junto con las bibliotecas Pandas y Scikit-learn, con el fin de visualizar y preprocesar los datos. Los resultados de esta implementación se detallarán en la fase 4 de la investigación.

4. Modelado: En esta etapa se detallarán los algoritmos que serán utilizados por el sistema de recomendación. El proceso correspondiente a esta fase se describe en la fase 4 de la investigación.
5. Evaluación: En esta etapa se verifica que el sistema cumpla con todas las características definidas y se evalúa la precisión del modelo para determinar si es necesario realizar ajustes. El proceso correspondiente a esta fase se desarrolla en la fase 5 de la investigación.
6. Despliegue: En esta etapa, se busca que los usuarios interactúen con el sistema de recomendación para capturar sus acciones, alimentar el modelo y generar nuevas listas de recomendaciones. El proceso de despliegue utilizado se describe con más detalle en la Fase 4.

Definición y análisis de requerimientos

En base a la información obtenida a través de los trabajos de investigación, tesis de grado, y artículos científicos recopilados en el capítulo del marco teórico. Se establecen los requerimientos funcionales y no funcionales que debe cumplir el sistema de recomendación.

Requerimientos funcionales

- El sistema debe construir una matriz de adyacencia en base al conjunto de productos y las interacciones de los usuarios con estos.
- El sistema debe verificar que haya nuevas interacciones de los usuarios con los productos para generar nuevas recomendaciones.
- El sistema debe implementar el algoritmo de predicción de enlaces utilizando la técnica de factorización de matrices no negativas.

- El sistema debe entrenar el modelo de predicción de enlaces utilizando los datos procesados y las características generadas.
- El sistema debe evaluar el rendimiento del modelo de predicción de enlaces utilizando las métricas *precision@k* y *ROC-AUC*.
- El sistema debe permitir el ajuste de hiperparámetros del modelo de predicción de enlaces para optimizar su rendimiento.

Requerimientos no funcionales

- El sistema debe manejar datos a gran escala de manera eficiente.
- El sistema debe asegurar que los datos de usuarios utilizados para las predicciones sean manejados de manera segura.

Fase 3. Diseñar el sistema, modelo arquitectónico, estructura de datos e interfaces

En esta fase se establecen los fundamentos del sistema, tomando como referencia los requerimientos previamente definidos. Además, se incluye la selección de los conjuntos de datos a utilizar, el modelado de la base de datos, y el diseño de la arquitectura del sistema.

Establecer la arquitectura del sistema de recomendación de acuerdo a los requerimientos previamente definidos

En esta fase, se enfatiza la importancia de seleccionar y diseñar la arquitectura de software. Según [Cervantes\(2020\)](#), evaluar y documentar la arquitectura garantiza un sistema de alta calidad que cumpla con los requisitos

y permita identificar errores tempranos, reduciendo riesgos en etapas posteriores del desarrollo.

Considerando lo anteriormente expuesto, se optó por la arquitectura Separación de la lógica de negocio de los modelos de ML propuesta por [Yokoyama \(2019\)](#). La elección fue tomada: debido a que la arquitectura separa claramente los componentes del sub sistema de software del sub sistema de ML. De esta manera, se desacopla la lógica de negocio del proceso predictivo. En la [Figura 9](#) se puede observar el flujo de datos entre los componentes de la arquitectura.




Figura 9. Arquitectura del sistema de recomendación

El sistema se divide en dos subsistemas principales. El primero es un subsistema de software que captura las interacciones de los usuarios a través de una interfaz web y gestiona la lógica de negocio. El segundo está compuesto por los componentes del sistema de recomendación, responsables de procesar los datos y realizar las predicciones mediante un modelo de

predicción enlaces basado en grafos de interacción y técnicas de aprendizaje automático no supervisado. Estos subsistemas trabajan de manera integrada, retroalimentándose para mejorar la precisión de las recomendaciones.

Colección de datos a utilizar

Para el desarrollo del sistema se ha decidido utilizar la colección de datos de productos electrónicos, compartida por [Agrawal \(2022\)](#) en la plataforma Kaggle. Esta última tiene su origen en la publicación original de [Datafiniti y Nicholle@Datafiniti \(2018\)](#) también publicada en la misma plataforma, la cual inicialmente contenía un total de 14,592 registros y 31 columnas, los cuales fueron extraídos de la base de datos de Datafiniti. Esta empresa se especializa en recopilar y agregar datos de diversas fuentes en línea, como sitios web de comercio electrónico, sitios de reseñas, directorios de empresas y otras plataformas, mediante la aplicación continua de técnicas de raspado de web (*web scraping*, en inglés), validación, y combinación de datos en una fuente unificada.

De esta manera, [Agrawal \(2022\)](#) llevó a cabo un proceso de preprocesamiento de los datos sobre el conjunto de datos original, abordando la gestión de valores faltantes, la normalización de unidades, y la selección de características relevantes. Como resultado obtuvo un conjunto de datos limpio y estructurado, compuesto por 14.557 registros y 25 variables, los cuales fueron almacenados en un documento en formato CSV.

Tabla 3. *Diccionario de datos del dataset de productos*

Característica	Tipo	Descripción
Id	Numérico	Identificador único del producto.
Actual_price	Numérico	Precio del producto

Discount_price	Numérico	Precio con descuento del producto.
Product_availability	Texto	Disponibilidad del producto (ej., "Yes", "No")
Brand	Texto	Marca del producto
Condition	Texto	Condición del producto (ej., "New", "Used").
Currency	Texto	Moneda del precio (e.j., "USD").
Country	Texto	País donde se ofrece el producto.
isSale	Booleano	Indicador de si el producto está en oferta (ej., True/False).
Merchant	Texto	Nombre del comerciante.
Description	Texto	Descripción del producto.
Category_name	Texto	Categoría del producto.
primaryCategories	Texto	Contiene la categoría principal del producto.
Name	Texto	Nombre del producto
weight_in_kg	Numérico	Peso del producto en kilogramos
Impression	Numérico	Número de impresiones del producto.
Day	Numérico	Día de la fecha relacionada con la venta del producto.
Month	Numérico	Mes de la fecha relacionada con la venta del producto.
Year	Numérico	Año de la fecha relacionada con la venta del producto.
Week	Numérico	Semana de la fecha relacionada la venta del producto.
Month_Name	Texto	Nombre del mes
Day_Name	Texto	Nombre del día
Formatted_date	Fecha	Fecha formateada
Disc_Per	Numérico	Porcentaje de descuento.
Total_sale	Numérico	Venta total del producto.

Identificar los datos abstractos y sus relaciones

En base al análisis del problema, y los requerimientos definidos previamente, se pudo obtener los fundamentos para la construcción de las estructuras abstractas que serán parte del modelo de la base de datos.

En la [Figura 10](#) se puede observar el modelo entidad–relación (MER) el cual consta de un conjunto de entidades y relaciones que cumplen las necesidades del sistema de recomendación. Cada entidad contiene un conjunto de atributos representativos. Asimismo, existen relaciones entre las entidades, que ayudan a representar como se asocian los elementos del modelo. Entre las entidades se encuentran categoría de productos, productos, sesión de compra, orden, usuario, usuario administrador, tipo de administrador, productos recomendados, y detalles de pago. Así, entre las relaciones más importantes se encuentra la relación entre usuario y producto, que establece las interacciones que ha tenido un usuario con los productos. Luego se encuentra la relación usuario y productos recomendados, la cual indica los productos que han sido recomendado para un determinado usuario.




Figura 10. Modelo Entidad - Relación de la base de datos

En base al modelo entidad – relación, se establece el modelo relacional el cual refleja como las entidades y sus datos fundamentales son almacenados en la base datos con el fin de servir a las funcionalidades del sistema, el modelo se encuentra en el [Anexo A](#) junto a su correspondiente explicación.

Fase 4. Desarrollar el sistema de recomendación basado en técnicas de predicción de enlaces

En esta fase, se procederá a desarrollar un sistema de recomendación utilizando técnicas de predicción de enlaces. Este enfoque se basa en la idea de predecir interacciones futuras entre usuarios y productos, analizando las conexiones existentes y los patrones dentro de los datos. El desarrollo de este sistema se ha llevado a cabo utilizando un conjunto de herramientas y técnicas

de aprendizaje automático, cuyo código fuente completo está disponible en nuestro repositorio de GitHub (véase el [Anexo E](#)).

Procesamiento de los datos

Tomando como bases las características relevantes de la colección de productos, es necesario estandarizar y calcular datos derivados, los cuales van a ser utilizados por los algoritmos que conforman el modelo del sistema de recomendación. Para ello se va a requerir aplicar técnicas de transformación y codificación sobre algunas de las características existentes.

Preparación de los datos

En primer lugar, se realizó una reducción del conjunto de datos de productos electrónicos, para ello se implementó la técnica de muestreo estratificado donde se quiere representar un 0.7% de los productos de cada categoría. La selección de los elementos de cada estrato es aleatoria y se mantiene la proporción de cada categoría, dando como resultado un conjunto de datos de 66 registros.

Posteriormente se seleccionó las características que serán utilizadas por el modelo del sistema de recomendación. En primer lugar, se examinó las estadísticas descriptivas de la columna *Actual_price*.




Figura 11. Distribución de la columna *Actual_price*

En la [Figura 11](#) se puede observar que la media es mayor que la mediana, por lo tanto, la distribución presenta un sesgo positivo. Para normalizar la distribución es necesario eliminar los valores atípicos ubicados en la cola derecha y aplicar una transformación sobre los datos. En la [Figura 12](#) se puede observar un diagrama de cajas con la distribución de los valores de *Actual_price*.




Figura 12. Diagrama de caja de la característica *Actual_price*

En la figura anterior se observa que la mayoría de los valores de *Actual_price* están definidos dentro del rango intercuartílico. Además, existe la presencia de valores atípicos que están por encima del límite superior, estos se encuentran representados como puntos. En la [Figura 13](#) se presentan algunos de los valores de la propiedad *Actual_price* que se consideran como anormales.

	id	Actual_price
72	AV_OF0yrHh53nbDRAGw0	1299.99
70	AWOpLyzrHh53nbDRKmTD	1398.00
37	AVph0xQQ1cnluZ0-_-Nn	1701.69
64	AVzSv0q-vKc47QAVd60B	1887.95
68	AV1YHofqglJLPUI8IGyn	3699.99

Figura 13. Valores anormales en la columna *Actual_price*

Para eliminar los valores anormales se procedió a utilizar el método del rango intercuartílico (RIC). Así, una vez eliminado los valores anormales que estaban por encima del límite superior se observó nuevamente la distribución de la característica *Actual_price*.




Figura 14. Distribución de la característica *Actual_price* después de eliminar los valores anormales.

Tal como se puede observar en la [Figura 14](#), la distribución de los datos aun presenta un sesgo positivo, por lo tanto, es necesario aplicar la transformación logarítmica de base 10 para normalizar la distribución, para ello se va a utilizar la biblioteca *numpy* la cual incluye la utilidad para aplicar transformación logarítmica de base 10 sobre la columna *Actual_price*.

```
actual_price_log = np.log1p(df['Actual_price'] + LITTLE_CONSTANT_LOG_10_TRANSFORM).tolist()
actual_price_log = format_decimals(actual_price_log, 4)
df['Actual_price_log'] = actual_price_log
```

Figura 15. Aplicación de la transformación logarítmica de base 10 en la columna *Actual_price*

En la [Figura 15](#) se puede observar la aplicación de la transformación logarítmica sobre la columna *Actual_price* la cual da como resultado la columna *Actual_price_log*. Esta contiene los precios de los productos expresados en escala logarítmica, en la [Figura 16](#) se puede visualizar la distribución de la propiedad derivada (Histograma azul) en comparación con una distribución normal (Histograma rojo).




Figura 16. Distribución de la característica *Actual_price_log*.

La columna *Category_name* la cual es un tipo de dato categórico también va a ser utilizada como entrada para el modelo del sistema de recomendación. No obstante, la propiedad debe ser convertida en un tipo de dato numérico para su uso. Así, antes de procesar la columna es necesario analizarla. Primero se debe agrupar el conjunto de datos de acuerdo a las

categorías existentes y determinar la cantidad de productos por cada una de estas, esto último por medio del uso de la librería Pandas.

Del procedimiento anterior se obtuvo que existen 36 categorías, también se determinó el número de productos clasificados bajo cada categoría. En la [Tabla 4](#) se observa el nombre de las categorías junto con la frecuencia en el conjunto de datos.

Tabla 4. *Productos agrupados por categorías*

Nombre de la categoría	Frecuencia	Precio promedio por categoría (\$)
camera, bag	1	59.74
camera, camcorder, action	1	50.99
camera, mirrorless	1	8.40
camera, shoot, point	3	449.37
car, gps, dash	4	258.89
car, speaker, subwoofer	2	87.99
card, memory, camera	1	89.99
case, computer	2	72.49
Desktop	1	669.00
drive, storage, hard	6	126.14
Headphone	3	172.66
headphone, earbud, bluetooth	3	182.98
headset, game, computer	1	59.99
keyboard, computer, mouse	1	99.99
laptop, computer	2	694.49
laptop, computer, macbook	1	899.99
lens, camera	1	399.00
memory, computer, component	1	74.85
monitor, computer	2	377.81
mount, tv, stand	1	144.99
mouse, keyboard	1	51.68
networking, adapter, switch	1	29.99
networking, modem, router	1	179.99
phone, cell	1	89.00
player, ipod	2	324.99
projector, presentation, screen	1	549.99

receiver, amplifier, home	3	554.99
sound, speaker, home	2	462.99
speaker, audio	2	230.94
speaker, bluetooth, mobile	1	148.00
speaker, portable, bluetooth	2	58.57
tablet, computer, ipad	3	268.32
tv, 4k, televisión	2	608.00
tv, streaming, médium	1	171.16
tv, television, led	4	466.99
wireless, speaker, audio	1	448.00

Para codificar la variable *category_name* se va a implementar la técnica *K- fold target encoding*. Para ello se va a utilizar el precio promedio por categoría como variable objetivo. En la [Figura 17](#) se ilustra cómo se emplea los *Dataframes* de *Pandas* para agrupar los productos por categoría y calcular el promedio del precio para cada una. Los resultados se presentan en la Tabla 4, donde se observan los precios promedio por categoría, que serán utilizados en el proceso de codificación.

```
#1) Obtengo el precio promedio por Categoría
actual_price_mean_grouped_by_category_name = df.groupby("Category_name")["Actual_price"].mean().reset_index()
actual_price_mean_grouped_by_category_name.columns = ['Category_name', 'Actual_price_mean_by_category_name']

actual_price_meand_by_category_serie = actual_price_mean_grouped_by_category_name['Actual_price_mean_by_category_name']
actual_price_meand_by_category_serie = format_decimals(actual_price_meand_by_category_serie, 4)
actual_price_mean_grouped_by_category_name['Actual_price_mean_by_category_name'] = actual_price_meand_by_category_serie

df = pd.merge(df, actual_price_mean_grouped_by_category_name, on='Category_name', how='left')
```

Figura 17. Cálculo del promedio de precio de los productos por categoría

De esta manera, se procede a implementar el algoritmo *K – Fold target encoding*. Es necesario tener en cuenta que puede haber duplicados en los valores si existen precios promedios iguales por categoría, por lo tanto, para evitar esto se ha agregado una constante pequeña al promedio del precio de cada categoría.

```

# 2) ENCODING Category_name COLUMN USING K-FOLD TARGET ENCODING

category_name = df['Category_name'].to_numpy().reshape(-1, 1)
actual_price_mean_grouped_by_category = df['Actual_price_mean_by_category_name'].to_numpy()

# Agregar algo de ruido para evitar codificaciones exactas, esto es util cuando hay valores iguales en la
# variable target
actual_price_mean_grouped_by_category_noisy = actual_price_mean_grouped_by_category + np.random.normal(0, 0.10,
                                                    size=actual_price_mean_grouped_by_category.size)

# Crear una columna temporal para almacenar las codificaciones k-fold
df['Category_name_encoded'] = 0.0

te = TargetEncoder(target_type="continuous", smooth=2.0, shuffle=False)
te.fit_transform(category_name, actual_price_mean_grouped_by_category_noisy)

category_name_encoded = te.transform(category_name)

df['Category_name_encoded'] = category_name_encoded[:, 0]

result = np.array([[category[0], category_name_encoded[idx][0]] for idx, category in enumerate(category_name)])

```

Figura 18. Codificación de la columna *Category_name* utilizando K-fold target encoding

Las categorías obtenidas fueron almacenadas en la columna *Category_name_encoded* del *Dataframe*. El nuevo valor para cada una indica la tendencia o el comportamiento del precio dentro de esa categoría. En la [Tabla 5](#) se muestra los valores codificados.

Tabla 5. Categorías de productos codificadas

Categoría	Valor codificado
camera, bag	207.89
camera, camcorder, action	204.91
camera, mirrorless	190.73
camera, shoot, point	382.38
car, gps, dash	266.65
car, speaker, subwoofer	184.93
card, memory, camera	218.00
case, computer	177.23
Desktop	410.91
drive, storage, hard	165.09
Headphone	216.37
headphone, earbud, Bluetooth	222.52
headset, game, computer	207.89
keyboard, computer, mouse	221.27

laptop, computer	488.19
laptop, computer, macbook	487.95
lens, camera	320.93
memory, computer, component	212.98
monitor, computer	329.83
mount, tv, stand	236.28
mouse, keyboard	205.18
networking, adapter, switch	197.98
networking, modem, router	247.95
phone, cell	217.61
player, ipod	303.48
projector, presentation, screen	371.27
receiver, amplifier, home	445.76
sound, speaker, home	372.44
speaker, audio	256.42
speaker, bluetooth, mobile	237.28
speaker, portable, Bluetooth	170.27
tablet, computer, ipad	273.78
tv, 4k, televisión	444.99
tv, streaming, médium	245.02
tv, television, led	405.30
wireless, speaker, audio	337.28

Una vez que se ha codificado la columna *category_name*, se procede a obtener las estadísticas descriptivas y la distribución de los datos. En la [Figura 19](#) se muestra un histograma de las categorías codificadas.




Figura 19. Distribución de la característica *Category_name_encoded*

Como se puede observar en la figura anterior, la media es mayor que la mediana, lo que indica un sesgo positivo en la distribución de la característica *Category_name_encoded*, Por lo tanto, es necesario aplicar una transformación logarítmica de base 10 para normalizar los datos y reducir el sesgo.

```
# Dado al sesgo positivo, aplico transformación logarítmica para suavizar la cola derecha
df['Category_name_encoded_log'] = np.log1p(df['Category_name_encoded'] + LITTLE_CONSTANT_LOG_10_TRANSFORM).tolist()
category_name_encoded_log = df['Category_name_encoded_log']
category_name_encoded_log = format_decimals(category_name_encoded_log, 4)
df['Category_name_encoded_log'] = category_name_encoded_log
```

Figura 20. Transformación logarítmica de base 10 aplicada sobre *Category_name_encoded*

En la [Figura 20](#) se muestra la aplicación de la transformación logarítmica sobre la columna *Category_name_encoded*, lo que genera la nueva columna *Category_name_encoded_log*, que contiene la codificación de

las categorías de productos en escala logarítmica. En la [Figura 21](#), se puede observar la distribución de esta nueva columna, donde se aprecia una menor diferencia entre la media y la mediana, lo que indica una mejora en la normalización de los datos.




Figura 21. Distribución de la característica *Category_name_encoded* después de aplicar la transformación logarítmica de base 10

Obtención de la información para el modelo del sistema de recomendación

Para realizar las predicciones, el modelo de recomendación necesita información de entrada que incluye: una matriz de adyacencia basada en las interacciones de los usuarios con los productos, así como matrices de pertenencia a una comunidad y de similitud de atributos, las cuales son construidas a partir de las características de los productos.

La matriz de adyacencia es una estructura de dimensión $n \times n$, donde n es el número de productos del conjunto de datos. Las entradas de esta matriz tienen valores definidos en el rango discreto $[0, 1]$. Un valor de 1 se asigna a una entrada si el número de usuarios que han interactuado con un par de elementos supera un umbral específico; en esta investigación, dicho umbral es de dos. Esto significa que para que exista un enlace entre dos productos, al menos dos usuarios deben haber interactuado con ambos. De lo contrario, la entrada se asignará un valor de cero.

Para obtener el total de usuarios que han interactuado con cada par de elementos posibles, es necesario realizar una consulta al historial de interacciones almacenado en la base de datos.

```
def get_user_product_interactions(cursor):  
    query = """  
        SELECT product_id1, product_id2, COUNT(DISTINCT user_id) AS count_users  
        FROM (  
            SELECT LEAST(i1.product_id, i2.product_id) AS product_id1,  
                   GREATEST(i1.product_id, i2.product_id) AS product_id2,  
                   i1.user_id  
            FROM cart_user_product_interactions AS i1  
            INNER JOIN cart_user_product_interactions AS i2 ON i1.user_id = i2.user_id  
            WHERE i1.product_id != i2.product_id  
        ) AS subquery  
        GROUP BY product_id1, product_id2;  
    """
```

Figura 22. Consulta SQL para obtener el número de usuarios que han interactuado con cada par de productos.

Así, el resultado consiste en el peso de los enlaces por cada par de elementos, en la [Figura 23](#) se observa los primeros 30 elementos de la consulta.

	product_id_1	product_id_2	weight
0	0	1	9
1	0	2	3
2	0	3	5
3	0	4	5
4	0	5	4
5	0	6	6
6	0	7	2
7	0	8	4
8	0	9	7
9	0	10	2
10	0	11	2
11	0	12	1
12	0	13	2
13	0	15	3
14	0	16	2
15	0	17	8
16	0	18	2
17	0	20	1
18	0	23	3
19	0	24	1
20	0	25	1
21	0	26	2
22	0	27	1
23	0	30	1
24	0	31	2
25	0	33	2
26	0	34	1
27	0	35	8
28	0	40	1
29	0	42	1

Figura 23. Número de usuarios que han interactuado con los primeros 30 pares de productos.

Una vez obtenido el peso de los enlaces por cada par de elementos, se debe inicializar una matriz de adyacencia nula de dimensión $n \times n$ que va a servir como base para representar los enlaces existentes en el grafo de interacción. En la [Figura 24](#) se observa cómo se itera la lista compuesta por tuplas, las cuales contienen el identificador de ambos elementos y el número de interacciones. En base a esta información se establece los valores de las entradas de la matriz de adyacencia.

```
def _update_adjacency_matrix(interactions, adjacency_matrix, weight_threshold = 2):
    for i1, i2, weight in interactions:
        if (weight >= weight_threshold):
            adjacency_matrix[i1][i2] = 1
            adjacency_matrix[i2][i1] = 1
    return adjacency_matrix
```

Figura 24. Construcción de la matriz de adyacencia

En la [Figura 25](#) se ilustran las primeras 20 filas y columnas de la matriz de adyacencia. Las entradas en blanco indican productos con los que han interactuado al menos dos usuarios, mientras que las entradas en negro representan productos que no cumplen con el umbral definido previamente. Por ejemplo, la entrada (0, 3), correspondiente a los productos con identificadores 0 y 3, está coloreada de blanco, lo que indica que al menos dos usuarios han interactuado con ambos productos.




Figura 25. Submatriz de adyacencia para los primeros 20 nodos de la red.

Para obtener las matrices de pertenencia a una comunidad y de similitud de atributos, se emplean las características derivadas obtenidas durante el procesamiento de los datos, que incluyen: *Actual_price_log*, y *Category_name_encoded_log*.

Por tal motivo, para construir la matriz de pertenencia a la comunidad, se utiliza la técnica de agrupamiento *K-means*, la cual agrupa los productos en clústeres según la similitud de sus vectores de características. Este enfoque sugiere que los productos dentro de un mismo grupo representan diferentes segmentos de mercado basados en rangos de precios. Además, dentro de cada rango, los productos se organizan por categorías similares, lo que facilita la identificación de patrones de consumo y permite una segmentación más precisa.

```

# BUILDING COMMUNITY MEMBERSHIP INFORMATION MATRIX

# Applying K-MEANS to build community membership information matrix
kmeans_kwargs = {
    "init": "k-means++",
    "n_init": 10,
    "max_iter": 300,
}

# Applying k-means clustering

# n_clusters must be selected according to elbow_method and silhouette_score
n_clusters = 2
kmeans_df = apply_kmeans(scaled_features, n_clusters, kmeans_kwargs, feature_names=column_names)
community_matrix = build_community_information_matrix(cluster_assignments=kmeans_df["predicted_cluster"])

```

Figura 26. Obtención de la matriz de pertenencia utilizando el algoritmo de agrupamiento K-means

El proceso descrito anteriormente sirve para construir una matriz de dimensiones $n \times n$, donde n es el número de productos del conjunto de datos. Cada fila y columna de la matriz corresponde a un producto. Las entradas de la matriz adoptan valores discretos definidos en el rango $[0, 1]$, asignando un valor de 0 cuando dos productos no pertenecen al mismo grupo, y 1 cuando comparten grupo.




Figura 27. Submatriz de pertenencia a una comunidad para los primeros 20 nodos de la red

En la [Figura 27](#) se muestra una subsección de las primeras 20 filas y columnas de la matriz de pertenencia a comunidades. Las celdas blancas indican que los productos pertenecen al mismo grupo, mientras que las celdas negras reflejan que los productos no comparten grupo. La diagonal principal es completamente blanca, ya que un producto siempre pertenece a su propio grupo. Por ejemplo, la entrada (0, 3), correspondiente a los productos con identificadores 0 y 3, está coloreada de negro, lo que indica que ambos productos no comparten el mismo grupo.

Por otro lado, para construir la matriz de similitud de atributos entre productos, se empleará la medida de similitud basada en el *RBF kernel*, que permite calcular la distancia entre los vectores de características de los productos. La [Figura 28](#) muestra la implementación de este método,

representado por una función que recibe como parámetro el conjunto de vectores de características y devuelve una matriz de similitud entre los productos.

```
def apply_rbf_to_get_similarity(features, gamma=1):  
    rbf_matrix = rbf_kernel(features, gamma=gamma)  
    return rbf_matrix
```

Figura 28. Implementación de la medida de similitud RBF kernel

El procedimiento anterior genera una matriz de dimensiones $n \times n$, donde n es el número de productos en el conjunto de datos. Las filas y columnas corresponden a cada producto, y las entradas de la matriz toman valores dentro del rango continuo $[0, 1]$. Un valor de 0 indica que no hay similitud entre los vectores de características de los productos, mientras que un valor de 1 refleja que ambos productos son completamente similares. Así, cada valor en la matriz representa el grado de similitud entre los productos comparados.

```
[[1.      0.9909 0.2876 0.0182 0.3297 0.2074 0.8307 0.4106 0.7062 0.1313]  
 [0.9909 1.      0.3521 0.0125 0.3028 0.1717 0.7973 0.3411 0.6356 0.0992]  
 [0.2876 0.3521 1.      0.0001 0.0522 0.0095 0.1852 0.0162 0.0727 0.0016]  
 [0.0182 0.0125 0.0001 1.      0.0833 0.3577 0.045  0.3224 0.1259 0.6044]  
 [0.3297 0.3028 0.0522 0.0833 1.      0.7287 0.6785 0.4115 0.6319 0.1507]  
 [0.2074 0.1717 0.0095 0.3577 0.7287 1.      0.4557 0.6673 0.6285 0.4376]  
 [0.8307 0.7973 0.1852 0.045  0.6785 0.4557 1.      0.5414 0.8853 0.1839]  
 [0.4106 0.3411 0.0162 0.3224 0.4115 0.6673 0.5414 1.      0.8281 0.7647]  
 [0.7062 0.6356 0.0727 0.1259 0.6319 0.6285 0.8853 0.8281 1.      0.4038]  
 [0.1313 0.0992 0.0016 0.6044 0.1507 0.4376 0.1839 0.7647 0.4038 1.      ]]
```

Figura 29. Submatriz de similitud de atributos para los primeros 10 nodos de la red

En la [Figura 29](#) se muestra una subsección de las primeras 10 filas y columnas de la matriz de similitud de atributos. Se puede notar que la diagonal principal tiene únicamente valores de 1, ya que cada producto es completamente similar a sí mismo. Por ejemplo, en la entrada (0, 3), correspondiente a los productos con identificadores 0 y 3, se observa una baja similitud, con un valor de 0.0182.

Construcción del sistema de recomendación

El modelo de recomendación implementado en esta investigación se basa en el modelo ACCSLP propuesto por [Tang y Wang, \(2022\)](#). La elección de este modelo responde a la falta de información inicial sobre las interacciones entre usuarios y productos, lo que obliga al sistema a utilizar los atributos de los nodos del grafo para complementar la información topológica de la red. El modelo utiliza tres fuentes de información: la matriz de adyacencia, la matriz de pertenencia a una comunidad y la matriz de similitud de atributos. A continuación, cada una de estas matrices es descompuesta mediante el método de Descomposición en valores singulares (SVD), como se ilustra en la [Figura 30](#), obteniendo dos matrices de dimensiones reducidas por cada una de las matrices principales.

```
# initialize or check W and H
U, H = self._initialize_w_h(S, matrix_target="Matrix S")
W, R = self._initialize_w_h(X, matrix_target="Matrix X")
L, V = self._initialize_w_h(Z, matrix_target="Matrix Z")
```

Figura 30. Descomposición de las matrices de adyacencia, pertenencia a una comunidad, y similitud de atributos

Después que se han inicializado, se toman las matrices bases U y W , y las matrices de coeficientes H y V , para fusionarlas a través de las reglas de actualización multiplicativa del algoritmo de factorización de matrices no negativas. En la [Figura 31](#) se puede observar el proceso iterativo el cual consiste en actualizar las matrices, evaluar la función de pérdida, y determinar si el error devuelto por la función objetivo es menor que un valor umbral definido. En caso de cumplirse esto último, significa que el algoritmo ha alcanzado la convergencia, en otras palabras, ha alcanzado un punto donde se ha logrado una aproximación razonablemente buena de la matriz original.

```
def _fit_multiplicative_update(S,X,Z,U,H,W,V,alpha,beta,beta_loss="kullback-leibler",max_iter=200,tol=1e-4,verbose=0,):
    beta_loss = _beta_loss_to_float(beta_loss)

    # used for the convergence criterion
    error_at_init = _beta_divergence(S=S, X=X, Z=Z, U=U, H=H, W=W, V=V, alpha=alpha, beta=beta, loss_function=beta_loss)
    previous_error = error_at_init

    for n_iter in range(1, max_iter + 1):
        # update U
        U = _multiplicative_update_u(S=S, Z=Z,U=U,H=H,V=V,beta=beta,)
        H = _multiplicative_update_h(S=S,X=X,U=U,W=W,H=H,alpha=alpha,)
        W = _multiplicative_update_w(X=X,W=W,H=H,)
        V = _multiplicative_update_v(Z=Z,U=U,V=V)

        # test convergence criterion every 10 iterations
        if tol > 0 and n_iter % 10 == 0:
            error = _beta_divergence(S=S, X=X, Z=Z, U=U, H=H, W=W, V=V, alpha=alpha, beta=beta, loss_function=beta_loss)

            if (previous_error - error) / error_at_init < tol:
                break
            previous_error = error

    return U, H, n_iter
```

Figura 31. Proceso de factorización de matrices no negativas

Finalmente, se retorna la matriz base U y la matriz de coeficiente H . La multiplicación matricial de ambas da como resultado una aproximación a la matriz de adyacencia S , esta es representada como la matriz S' la cual va a contener los puntajes o scores de cada par de vértices, cuyo valor representa la probabilidad de que en un futuro se cree un enlace entre ambos.

La función de pérdida utilizada fue la divergencia generalizada de Kullback-Leibler. En la [Figura 32](#), se ilustran los parámetros de balance, alfa y beta, que regulan el impacto de la información complementaria proveniente de las matrices de pertenencia a la comunidad y de similitud de atributos.

```
def _beta_divergence(S, X, Z, U, H, W, V, alpha, beta, loss_function="kullback-leibler"):

    UH = np.dot(U, H)
    UH_data = UH.ravel()
    S_data = S.ravel()

    WH = np.dot(W, H)
    WH_data = WH.ravel()
    X_data = X.ravel()

    UV = np.dot(U, V)
    UV_data = UV.ravel()
    Z_data = Z.ravel()

    indices = S_data > EPSILON
    S_data = S_data[indices]
    UH_data = UH_data[indices]

    zero_indices = WH_data == 0.0
    WH_data[zero_indices] = EPSILON

    zero_indices = UV_data == 0.0
    UV_data[zero_indices] = EPSILON

    sum_UH = np.dot(np.sum(U, axis=0), np.sum(H, axis=1))
    res = np.dot(S_data, np.log(UH_data))
    res_S = sum_UH - res

    sum_WH = np.dot(np.sum(W, axis=0), np.sum(H, axis=1))
    res = np.dot(X_data, np.log(WH_data))
    res_X = alpha * (sum_WH - res)

    sum_UV = np.dot(np.sum(U, axis=0), np.sum(V, axis=1))
    res = np.dot(Z_data, np.log(UV_data))
    res_Z = beta * (sum_UV - res)

    res = res_S + res_X + res_Z

    return res
```

Figura 32. Función de divergencia generalizada de Kullback – Leibler

Recomendación de los productos

El proceso de recomendación se activa únicamente cuando se registran interacciones entre usuarios y productos dentro de un intervalo de tiempo definido. Si esta condición se cumple, se ejecuta el modelo de predicción y se

genera la matriz de predicciones S' . En esta investigación, el intervalo de tiempo entre validaciones es de 10 minutos.

Después de obtener la matriz de predicciones S' , se procede a generar las listas de recomendaciones para cada usuario activo. Primero, se identifican los productos con los que los usuarios han interactuado y se obtienen las listas de similitud correspondientes a partir de la matriz S' . Luego, se crea una lista de recomendación personalizada para cada usuario, aplicando el método de votación ponderada para asignar un peso a cada producto. Finalmente, se seleccionan los primeros k elementos de la lista.

Despliegue del sistema de recomendación

Para habilitar la interacción de los usuarios con el sistema de recomendación, y recolectar la información necesaria para alimentar el modelo, se desplegó el sistema en producción utilizando el servicio de computación en la nube Render. Este servicio simplifica la gestión tanto de la arquitectura como de los recursos. Los servicios utilizados son los siguientes.

- Base de datos: Se utilizó una base de datos PostgreSQL para almacenar los datos de los productos, usuarios, interacciones entre usuarios y productos, listas de recomendación, sesiones, etc.
- Servicio web: Se utilizó para desplegar la plataforma de e-commerce, la cual da soporte al sistema de recomendación. Mediante esta plataforma se va a capturar la información de los productos con los que han interactuado los usuarios autenticados del sistema, en el [Anexo D](#) se ilustra los pasos del proceso. Además, los usuarios podrán ver los productos que han sido recomendados.
- Cron job: Ejecuta el proceso de recomendación cada 10 minutos, de tal manera que monitorea que al menos un usuario haya interactuado con

algún producto del sistema para generar nuevas listas de recomendación.

Active (0) Suspended (3) All (3)						
☐	Service name	Status	Type	Runtime	Region ↑	Last deployed
☐	 e-commerce	Suspended by you	Web Service	Docker	Oregon	2 months ago ...
☐	 e-commerce-cronjob	Suspended by you	Cron Job	Docker	Oregon	2 months ago ...
☐	 db	Suspended by you	PostgreSQL	PostgreSQL 16	Oregon	2 months ago ...

Figura 33. Dashboard de Render con los servicios implementados

Fase 5. Evaluar la precisión del sistema de recomendación

Una vez implementadas las funcionalidades del sistema de recomendación, es fundamental evaluar la precisión de las recomendaciones. Para calcular las medidas de precisión es necesario contar con los datos de interacción de los usuarios con los productos. La precisión global del modelo se va a medir utilizando el índice AUC-ROC, mientras que la precisión específica de las listas de recomendación va a ser medida mediante la métrica precision@k .

La base de datos cuenta con 208 registros que capturan las interacciones de los usuarios con los productos, estas están almacenadas en la tabla *cart_user_product_interactions*. Estos registros no solo proporcionan la información necesaria para construir el grafo, sino que también son fundamentales para predecir enlaces en el sistema. La precisión de las listas de recomendación se determinará con base en los primeros 10 elementos ($k = 10$) recomendados.

Evaluar la precisión del modelo

Primero, se calculará el índice AUC-ROC, que proporcionará una medida de la precisión general del modelo. Para ello, se construirá la matriz de adyacencia, siguiendo el procedimiento descrito anteriormente. Con esta matriz, se procederá a analizar la diagonal superior para identificar los elementos que no tienen enlaces, los cuales se almacenarán en una lista de pares de nodos. En la [Figura 34](#) se presentan los primeros 30 enlaces inexistentes en el grafo de interacción.

	product_id 1	product_id 2
0	0	12
1	0	14
2	0	19
3	0	20
4	0	21
5	0	22
6	0	24
7	0	25
8	0	27
9	0	28
10	0	29
11	0	30
12	0	32
13	0	34
14	0	36
15	0	37
16	0	38
17	0	39
18	0	40
19	0	41
20	0	42
21	0	43
22	0	44
23	0	47
24	0	48
25	0	49
26	0	50
27	0	51
28	0	52
29	0	53

Figura 34. Enlaces inexistentes del grafo de interacción.

Una vez identificados los enlaces inexistentes en la matriz de adyacencia, se procederá a generar un conjunto de enlaces de prueba. En

primer lugar, se debe seleccionar aleatoriamente un 40% de los productos existentes para crear combinaciones de pares. Posteriormente, se verifica si los enlaces están definidos en la matriz de adyacencia; en caso afirmativo, se eliminarán de la matriz y se agregarán a una lista de enlaces de evaluación. En la [Figura 35](#) se muestran los primeros 30 elementos del conjunto de enlaces de evaluación.

	product_id_1	product_id_2
0	0	2
1	0	3
2	0	4
3	0	5
4	0	7
5	0	8
6	0	9
7	0	13
8	0	18
9	0	26
10	0	35
11	0	45
12	0	57
13	0	65
14	2	3
15	2	4
16	2	5
17	2	7
18	2	8
19	2	9
20	2	12
21	2	35
22	2	57
23	2	59
24	3	4
25	3	5
26	3	7
27	3	8
28	3	9
29	3	12

Figura 35. Enlaces de evaluación para el cálculo del índice AUC

Además, este proceso también generará una matriz de adyacencia de entrenamiento, que excluye los enlaces que han sido eliminados. Así, al compararla con la matriz original presentada en la [Figura 36](#), se puede observar que la entrada (0, 3), correspondiente a los productos con

identificadores 0 y 3, no disponen de un enlace dado que ha sido extraído y añadido al conjunto de enlaces de prueba.




Figura 36. Submatriz de adyacencia de entrenamiento para los primeros 20 nodos de la red

Así, utilizando la matriz de adyacencia de entrenamiento obtenida, junto con las matrices de pertenencia a una comunidad y de similitud de atributos, generadas de manera similar a como se describió en la fase 4 del proyecto, se empleará esta información como entrada para el modelo de recomendación. Como resultado, se obtendrá una matriz de predicciones, cuyos primeros 20 elementos se muestran en la [Figura 37](#).




Figura 37. Submatriz de predicción para los primeros 20 nodos de la red.

A continuación, se calculará el índice AUC-ROC a través de una serie de 100,000 iteraciones, seleccionadas para evaluar la precisión del modelo. En cada iteración, se escogerá aleatoriamente un enlace del conjunto de prueba y otro del conjunto de enlaces faltantes, y se compararán sus pesos en la matriz de predicción.

```

def calculate_auc_index(test_set, unobserved_links, predicted_adj_matrix, n = 100000):

    i = 0
    n_sub_1 = 0
    n_sub_2 = 0

    while i < n:
        unobserved_link = random.choice(unobserved_links)
        unobserved_link_score = predicted_adj_matrix[unobserved_link[0], unobserved_link[1]]

        test_link = ()
        test_link_score = 0

        if len(test_set) > 0:
            test_link = random.choice(test_set)
            test_link_score = predicted_adj_matrix[test_link[0], test_link[1]]

        if test_link_score > unobserved_link_score:
            n_sub_1 = n_sub_1 + 1
        elif test_link_score == unobserved_link_score:
            n_sub_2 = n_sub_2 + 1

        i = i + 1

    auc_index = (n_sub_1 + 0.5 * n_sub_2)/n

    return auc_index

```

Figura 38. Cálculo del índice AUC

Una vez completado el procedimiento, el índice AUC-ROC obtenido es de 0.9123, lo que refleja un alto nivel de precisión del sistema para diferenciar entre elementos relevantes e irrelevantes. Esto significa que, en el 91.23% de los casos, el sistema asigna una puntuación mayor a un elemento relevante en comparación con uno irrelevante.

Evaluar la precisión de las listas de recomendación

Una vez evaluada la precisión general del modelo, es necesario calcular la precisión de las listas de recomendaciones para cada uno de los usuarios. A diferencia del índice AUC-ROC, que es un indicador absoluto que depende de todo el conjunto de enlaces, la precisión de las listas de recomendaciones es relativa a la longitud de la lista y a la cantidad de elementos con los que ha

interactuado cada usuario. En la [Figura 39](#) se muestra los productos con los que han interactuado los primeros 20 usuarios del sistema.

	user_id	products
0	2	[17]
1	5	[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 17, 35, 45, 46, 67]
2	7	[9]
3	9	[0, 4, 5, 6, 8, 9, 12, 13, 15, 16, 17, 18, 20, 23, 24, 25, 26, 67]
4	10	[25, 35]
5	11	[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 17, 23, 35, 61, 67]
6	12	[1]
7	14	[0, 1, 2, 3, 4, 5, 6, 13, 57, 59]
8	15	[3, 35]
9	16	[0, 1, 4, 17, 35]
10	17	[0, 1, 6, 9, 16, 17, 27, 31, 33, 35, 40, 45, 46, 52, 54, 57, 60, 61, 64, 65, 67]
11	18	[9]
12	19	[0, 1, 35, 67]
13	20	[35, 67]
14	23	[0]
15	25	[15, 35]
16	26	[1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 12, 17, 35, 67]
17	27	[0, 3, 9, 67]
18	29	[0, 1, 9, 17, 35]
19	30	[0, 1, 9, 15, 17, 26, 30, 31, 33, 34, 46, 50, 62, 65]

Figura 39. Lista de productos con los que han interactuado los usuarios

Con base en la información obtenida, se extraerá un 40% de los elementos para generar las listas de evaluación. En la [Figura 40](#) se presentan estas listas correspondientes a los primeros 28 usuarios.

	user_id	products
0	2	[]
1	5	[3, 1, 10, 0, 7, 2]
2	7	[]
3	9	[9, 4, 8, 24, 16, 12, 26]
4	10	[]
5	11	[5, 8, 10, 61, 17, 23]
6	12	[]
7	14	[2, 5, 59, 57]
8	15	[]
9	16	[4, 35]
10	17	[40, 65, 1, 6, 31, 0, 52, 17]
11	18	[]
12	19	[0]
13	20	[]
14	23	[]
15	25	[]
16	26	[4, 3, 7, 17, 8]
17	27	[3]
18	29	[35, 0]
19	30	[34, 30, 50, 62, 46]
20	31	[8]
21	32	[35, 3]
22	34	[]
23	35	[4, 35]
24	36	[42, 65]
25	37	[17, 18, 1, 3]
26	38	[25, 53, 63, 10, 15, 58, 23, 3, 49, 5, 11, 67, 50]
27	39	[0]

Figura 40. Lista de productos de evaluación para el cálculo de la medida $precision@k$

A continuación, se debe obtener la lista de enlaces a eliminar para cada usuario, basándose en la lista de productos con los que ha interactuado y el conjunto de enlaces de evaluación. Se verifica que cada combinación de pares de productos en la lista de interacción incluya al menos un producto en el conjunto de evaluación. Si es así, el par se almacena en una lista de enlaces para eliminar de la matriz de adyacencia. En la [Figura 41](#) se muestran los

primeros 30 elementos del conjunto de enlaces a eliminar para el usuario con ID 5.

	product_id_1	product_id_2
0	0	1
1	0	2
2	0	3
3	0	4
4	0	5
5	0	6
6	0	7
7	0	8
8	0	9
9	0	10
10	0	17
11	0	35
12	0	45
13	0	46
14	0	67
15	1	2
16	1	3
17	1	4
18	1	5
19	1	6
20	1	7
21	1	8
22	1	9
23	1	10
24	1	17
25	1	35
26	1	45
27	1	46
28	1	67
29	2	3

Figura 41. Pares de enlaces a eliminar para el usuario con ID 5

Una vez que se ha definido la lista de enlaces a eliminar para un usuario en específico, se procede a eliminar la interacción correspondiente de la lista de interacciones existentes.

```
def remove_node_links(links_weight, links_remove_list):
    i = 0
    links_weight_list = []
    for i1, i2, weight in links_weight:
        link = [i1, i2, weight]

        if i < len(links_remove_list) and i1 == links_remove_list[i][0] and i2 == links_remove_list[i][1]:
            link[2] = link[2] - 1
            i = i + 1
        links_weight_list.append(link)

    return links_weight_list
```

Figura 42. Eliminación de interacciones del usuario objetivo de la lista de interacciones.

Retomando el caso del usuario con ID 5, después de eliminar sus interacciones, se crea un nuevo conjunto de datos. En la [Figura 43](#) se muestran los primeros 30 elementos de este conjunto actualizado.

	product_id_1	product_id_2	weight
0	0	1	8
1	0	2	2
2	0	3	4
3	0	4	4
4	0	5	3
5	0	6	5
6	0	7	1
7	0	8	3
8	0	9	6
9	0	10	1
10	0	11	2
11	0	12	1
12	0	13	2
13	0	15	3
14	0	16	2
15	0	17	7
16	0	18	2
17	0	20	1
18	0	23	3
19	0	24	1
20	0	25	1
21	0	26	2
22	0	27	1
23	0	30	1
24	0	31	2
25	0	33	2
26	0	34	1
27	0	35	7
28	0	40	1
29	0	42	1

Figura 43. Conjunto de interacciones después de eliminar las interacciones del usuario con ID 5.

Con la información anterior se procederá a construir la matriz de adyacencia de la misma manera que se hizo en la sección anterior. La matriz resultante va a ser utilizada para determinar la lista de recomendaciones para el usuario objetivo, esto con el fin de implementar la métrica precision@k . En la [Figura 44](#) se puede observar los primeros 20 elementos de la matriz.




Figura 44. Submatriz de adyacencia para los primeros 20 nodos de la red, después de eliminar las interacciones del usuario con ID 5.

Así, utilizando la matriz de adyacencia resultante, junto con las matrices de pertenencia a una comunidad y de similitud de atributos, generadas de manera similar a como se describió en la fase 4 del proyecto, se empleará esta información como entrada para el modelo de recomendación. El objetivo es generar la matriz de predicciones, y obtener los primeros k elementos de la lista de recomendación. En la [Figura 45](#) se puede observar la lista de recomendación para el usuario objetivo.

	user_id	recommended_items
0	5	[1, 3, 0, 2, 7, 10]

Figura 45. Lista de recomendación para el usuario con ID 5

Con esto, una vez obtenidas las listas de recomendaciones para cada usuario siguiendo el procedimiento mencionado, se procede a calcular la métrica de precisión para cada una. Posteriormente, los valores obtenidos se promedian para obtener una visión general de la relevancia de los elementos recomendados.

```
def precision(row):
    """
    Funcion que va a implementar la metrica precision en k:
    (cuantos de los interactuados con el usuario estan entre los recomendados) / todos los recomendados
    """
    num_items_common = np.intersect1d(row['recom_items'], row['eval_items'])
    if len(row['recom_items']) == 0:
        return float(0)
    return float(len(num_items_common)/len(row['recom_items']))
```

Figura 46. Cálculo de la medida *precision@k*

Considerando lo anterior, se calculó la métrica de precisión en 23 listas de recomendación de productos, cada una asociada a un usuario, obteniendo un valor promedio de 0.6428. Esto indica que el 64.28% de los primeros 10 elementos recomendados son relevantes. En otras palabras, aproximadamente el 64.28% de las recomendaciones del sistema en estas posiciones se consideran correctas o útiles. Este resultado sugiere un rendimiento razonable del sistema de recomendación, aunque hay margen para mejorar. Una precisión del 64.28% implica que casi un tercio de las

recomendaciones no son pertinentes, lo que podría afectar la satisfacción del usuario y la eficacia general del sistema.

Evaluar la aceptabilidad de las recomendaciones por los usuarios

Para evaluar la aceptabilidad de las recomendaciones por parte de los usuarios, se diseñó un cuestionario de preguntas cerradas, disponible en el [Anexo B](#). Este cuestionario fue respondido por 20 usuarios del sistema, y las respuestas se ilustran en el [Anexo C](#).

En relación con la pregunta: “¿Qué tan fácil fue para ti encontrar productos relevantes con la ayuda del sistema de recomendación?”, los resultados indican que el 50% de los participantes (10 usuarios) consideran que fue “Muy fácil”, el 45% (9 usuarios) lo calificaron como “Fácil”, y una minoría del 5% (1 usuario) lo encontró “Muy difícil”. Por lo tanto, se puede concluir que el sistema es eficaz para recomendar productos relevantes a los usuarios, como se muestra en la [Figura 47](#).




Figura 47. *Facilidad para encontrar recomendaciones relevantes*

Para la pregunta “¿Qué tan precisas fueron las recomendaciones proporcionadas por el sistema en relación con tus preferencias?”, un 55% o 11 de los encuestados, destacan que las recomendaciones fueron “Precisas”, el

35% o 7 encuestados las calificaron como “Muy precisas”, mientras que 10% o 2 encuestados consideraron las recomendaciones como “Neutral”. Esto sugiere que la mayoría de los usuarios perciben que el sistema ofrece productos alineados con sus intereses, como se muestra en la [Figura 48](#).




Figura 48. Nivel de precisión de las recomendaciones

Por otro lado, a la pregunta “¿Qué tan satisfecho estás con la variedad de productos recomendados por el sistema?”, un 60% o 12 de los encuestados indicó estar “Muy satisfecho” con la diversidad de productos recomendados, el 35% o 7 encuestados expresó estar “Satisfecho”. Solo un 5% o 1 encuestado considera que esta “Muy insatisfecho”. Estos resultados sugieren que la mayoría de los usuarios valoran positivamente la diversidad de las recomendaciones, señalando que el sistema no solo ofrece productos previamente vistos, sino también nuevas opciones con las que no han interactuado. La tendencia de satisfacción con la variedad de recomendaciones puede observarse en la [Figura 49](#).




Figura 49. Diversidad de las recomendaciones

Por último, la pregunta “¿Qué tan probable es que recomiendes este sistema de recomendación a otras personas?”, un 75% o 15 de los encuestados indican que es “Muy probable” que recomienden el sistema a otros, un 20% o 4 encuestados han indicado que es “Probable” que lo recomienden, mientras que un 5% o 1 encuestado ha indicado que es “Muy improbable”. Estos resultados reflejan una alta satisfacción general con el sistema, como se puede visualizar en la [Figura 50](#).

¿Qué tan probable es que recomiendes este sistema de recomendación a otras personas?
20 respuestas




Figura 50. Probabilidad de recomendar el sistema de recomendación a otras personas

En conjunto, se observa una clara tendencia positiva hacia el uso del sistema de recomendación. La mayoría de los usuarios están satisfechos tanto

con la precisión como con la variedad de los productos recomendados, lo que los lleva a considerar recomendar el sistema a otras personas.

CONCLUSIONES

En línea con los objetivos planteados en esta investigación y los resultados obtenidos, se derivan las siguientes conclusiones.

A lo largo de este trabajo, se logró un entendimiento profundo de los principios fundamentales que subyacen en los sistemas de recomendación, lo que permitió establecer una base sólida para el posterior desarrollo del sistema propuesto.

Se identificaron y analizaron con éxito los requerimientos técnicos y funcionales necesarios para desarrollar un sistema de recomendación utilizando grafos de interacción.

Se seleccionó e identificó una arquitectura para el sistema de recomendación que no solo cumple con los requerimientos, sino que también distingue claramente entre la lógica de negocio y el modelo de predicción. Esta separación fue crucial para mantener la flexibilidad y escalabilidad del sistema.

Se determinaron y seleccionaron las herramientas y metodologías más apropiadas para el desarrollo del sistema, utilizando la metodología CRISP-DM como marco de trabajo. Esta metodología proporcionó una estructura clara para el desarrollo, desde la comprensión del problema hasta la implementación y evaluación del sistema.

Se diseñó el sistema de recomendación siguiendo la arquitectura previamente seleccionada, lo que permitió una integración coherente de todos los componentes y una clara distinción entre la lógica de negocio y el modelo del sistema de recomendación.

Finalmente, se llevaron a cabo mediciones que validaron la precisión del sistema de recomendación en un entorno con conocimiento mínimo. Los resultados obtenidos demostraron que el sistema es capaz de ofrecer recomendaciones relevantes y precisas, incluso en situaciones con información limitada sobre los usuarios, validando así la eficacia de la arquitectura y metodología seleccionadas.

RECOMENDACIONES

Para mejorar la precisión de las recomendaciones del sistema de recomendación y, en consecuencia, obtener mejores resultados en las medidas de precisión, se pueden seguir una serie de estrategias clave.

- Implementar el sistema de recomendación en entornos con un gran volumen de datos: La abundancia de datos permite que el modelo identifique patrones y relaciones más complejas, mejorando así la calidad de las recomendaciones.
- Ajustar los hiperparámetros del modelo de recomendación: Modificar los factores de regularización de las matrices complementarias, puede contribuir a optimizar el rendimiento del modelo.
- Aumentar la calidad y la cantidad de los datos de entrada: Esto implica no solo la limpieza de datos para eliminar errores y duplicados, sino también la incorporación de características relevantes adicionales que enriquezcan el conjunto de datos. Una base de datos más robusta permitirá mejorar las matrices de similitud y pertenencia a una comunidad.
- Incorporar la retroalimentación explícita de los usuarios: Recopilar calificaciones o comentarios de los usuarios permite personalizar las recomendaciones, adaptando el sistema a las preferencias individuales. Esta retroalimentación es esencial para ajustar las recomendaciones y aumentar su relevancia.
- Implementar un proceso automatizado para respaldar la base de datos. Este procedimiento garantizará la preservación de la información, que constituye una fuente esencial de datos para entrenar el modelo de recomendación y, en consecuencia, generar predicciones más precisas.
- Seleccionar conjuntos de datos y características alineados con el entorno en el cual se implementará el sistema de recomendación. Esta elección es fundamental para asegurar que el modelo se adapte correctamente a las necesidades específicas del contexto de uso.

REFERENCIAS

Aggarwal, C. (2016). *Recommender Systems: The textbook* (1a ed.). Springer.

Recuperado de

http://pzs.dstu.dp.ua/DataMining/recom/bibl/1aggarwal_c_c_recommender_systems_the_textbook.pdf

Agrawal, Y. (2022). *Price elasticity data cleaning—Part 1* [Data set]. Kaggle.

Recuperado de [https://www.kaggle.com/code/yugagrawal95/price-elasticity-data-cleaning-part-](https://www.kaggle.com/code/yugagrawal95/price-elasticity-data-cleaning-part-1?select=DatafinitiElectronicsProductsPricingData_Cleaned_dataset.csv)

[1?select=DatafinitiElectronicsProductsPricingData_Cleaned_dataset.csv](https://www.kaggle.com/code/yugagrawal95/price-elasticity-data-cleaning-part-1?select=DatafinitiElectronicsProductsPricingData_Cleaned_dataset.csv)

Arias, F. (2012). *El proyecto de investigación. Introducción a la metodología científica* (6a ed.). Episteme.

Athey, S. (2019). The impact of machine learning on economics. En A. Agrawal, J. Gans, y A. Goldfarb (Eds.), *The economics of artificial intelligence: An agenda* (pp. 507–547). University of Chicago Press.

Recuperado de

<https://www.nber.org/system/files/chapters/c14009/c14009.pdf>

Ayria, P. (2019, febrero 3). K-fold target encoding. Recuperado de

<https://medium.com/@pouryaayria/k-fold-target-encoding-dfe9a594874b>

- Bernstein, M. (2017). *The radial basis function kernel*. Recuperado de <https://pages.cs.wisc.edu/~matthewb/pages/notes/pdf/svms/RBFKernel.pdf>
- Bhandari, P. (2022, noviembre 5). How to find interquartile range (IQR): Calculator & examples. Recuperado de <https://www.scribbr.co.uk/stats/interquartile-range-meaning/>
- Brunton, S., y Kutz, N. (2017). *Data driven science & engineering machine learning, dynamical systems, and control*. Recuperado de <http://databookuw.com/databook.pdf>
- Castro, J., Gómez, L., y Camargo, E. (2022). La investigación aplicada y el desarrollo experimental en el fortalecimiento de las competencias de la sociedad del siglo XXI. *Tecnura*, 27(75), 140–174. Recuperado de <https://doi.org/10.14483/22487638.19171>
- Cervantes, H. (2020). Evaluación de la arquitectura de software. *Software Guru*, 31. Recuperado de <https://sg.com.mx/revista/31/arquitectura-evaluacion-la-arquitectura-software>
- Cortes, D. (2023, agosto 1). Introducción a los cron jobs. Recuperado de <https://medium.com/@diego.coder/introducci%C3%B3n-a-los-cron-jobs-6ae4801b5681>
- Datafiniti y Nicholle@Datafiniti. (2018). *Electronic products and pricing data* [Data set]. Recuperado de <https://www.kaggle.com/datasets/datafiniti/electronic-products-prices>

- Gan, J., Liu, T., Li, L., y Zhang, J. (2021). Non-negative matrix factorization: A survey. *The Computer Journal*, 64(7), 1081–1092. <https://doi.org/10.1093/comjnl/bxab103>
- Hotz, N. (2024, noviembre 18). What is CRISP DM? Recuperado de Data Science Process Alliance website: <https://www.data-science-pm.com/crisp-dm-2/>
- Hurtado de Barrera, J. (2010). *Metodología de la investigación: Guía para una comprensión holística de la ciencia* (4a ed.). Caracas, Venezuela: Quirón Ediciones.
- Isinkaye, F., Folajimi, Y., y Ojokoh, B. (2015). Recommendation systems: Principles, methods and evaluation. *Egyptian Informatics Journal*, 16(3), 261–273. <https://doi.org/10.1016/j.eij.2015.06.005>
- Linden, G., Smith, B., y York, J. (2003). Amazon.com recommendations: Item-to-item collaborative filtering. *IEEE Internet computing*, 7(1), 76–80. Recuperado de <https://www.cs.umd.edu/~samir/498/Amazon-Recommendations.pdf>
- Lozada, J. (2014). Investigación aplicada: Definición, propiedad intelectual e industria. *CienciAmérica*, 3(1), 47–50. Recuperado de <https://dialnet.unirioja.es/servlet/articulo?codigo=6163749>
- Luzanov, P., Rogov, E., y Levshin, I. (2023). *Postgres: The first experience. Postgres professional*. (9a ed.). Recuperado de https://edu.postgrespro.ru/introbook_v9_en.pdf

- Mark, L. (2009). *Learning Python* (4a ed.). Estados Unidos: O'Reilly.
Recuperado de https://ia801502.us.archive.org/18/items/learning-python-by-mark-lutz/Learning_Python%20by%20mark%20lutz.pdf
- Martínez, M. (2022). *Sistemas de recomendación y explicaciones basados en grafos de interacción* (Universidad Complutense de Madrid).
Universidad Complutense de Madrid, Madrid. Recuperado de <https://hdl.handle.net/20.500.14352/3551>
- Muccini, H., y Vaidhyanathan, K. (2021, marzo 16). *Software architecture for ML-based systems: What exists and what lies ahead*. Presentado en WAIN'21 - 1st Workshop on AI Engineering – Software Engineering for AI. <https://doi.org/10.48550/arXiv.2103.07950>
- Numpy. (s/f). Numpy Documentation. Recuperado el 6 de noviembre de 2023, de <https://numpy.org/doc/stable/>
- Pandas. (s/f). Pandas. Recuperado el 6 de noviembre de 2023, de <https://pandas.pydata.org/>
- Philip, S., Shola, P., y Abari, J. (2014). Application of content-based approach in research paper recommendation system for a digital Library. *IJACSA*, 5(10), 37–40. <https://dx.doi.org/10.14569/IJACSA.2014.051006>
- Piech, C. (2013). K-Means. Recuperado de Artificial intelligence: Principles and techniques website:
<https://stanford.edu/~cpiech/cs221/handouts/kmeans.html>
- Pressman, R. (2010). *Ingeniería del software. Un enfoque práctico* (7a ed.). McGraw-Hill.

Render. (s.f). About. Recuperado el 4 de octubre de 2024, de About website:

<https://render.com/about>

Runpakprakun, J., Washizaki, H., Khomh, F., Guéhéneuc, Y.-G., Yoshioka, N., y Fukazawa, Y. (2021). *Software engineering patterns for machine learning applications (SEP4MLA)—Part 3—Data processing architectures*. Presentado en Pattern Languages of Programs. Hillside.

Recuperado de

https://www.researchgate.net/publication/370414475_Software_Engineering_Patterns_for_Machine_Learning_Applications_SEP4MLA_-_Part_3_-_Data_Processing_Architectures

Sabino, C. (1992). *El proceso de investigación* (2a ed.). Caracas, Venezuela: Panapo.

Scikit-learn. (s/f). Pairwise metrics, affinities and kernels. Recuperado el 4 de abril de 2024, de <https://scikit-learn/stable/modules/metrics.html>

Silva, N., Carvalho, D., Pereira, A. C. M., Mourão, F., y Rocha, L. (2019). The pure cold-start problem: A deep study about how to conquer first-time users in recommendations domains. *Information Systems*, 80(1), 1–12. <https://doi.org/10.1016/j.is.2018.09.001>

Sommerville, I. (2016). *Software engineering* (10a ed.). United States of America: Pearson. Recuperado de <https://ia902306.us.archive.org/35/items/bme-vik-konyvek/Software%20Engineering%20-%20Ian%20Sommerville.pdf>

- Tang, M., y Wang, W. (2022). Cold-start link prediction integrating community information via multi-nonnegative matrix factorization. *Chaos, Solitons & Fractals*, 162(14). Recuperado de <https://www.sciencedirect.com/science/article/pii/S0960077922006312>
- Valecillos, O. (2020). *Desarrollo de un sistema de recomendaciones para un sitio de comercio electrónico* (Universidad Central de Venezuela). Universidad Central de Venezuela, Caracas. Recuperado de <http://saber.ucv.ve/handle/10872/20508>
- Wang, J., Ma, Y., y Yuan, Y. (2020, julio 5). *Towards fast evaluation of unsupervised link prediction by random sampling unobserved links*. arXiv. <https://doi.org/10.48550/arXiv.2002.09165>
- Washizaki, H., Khomh, F., Guéhéneuc, Y.-G., Takeuchi, H., Natori, N., Doi, T., y Okuda, S. (2022). Software engineering design patterns for machine learning applications. *IEEE Computer*, 55(3), 30–39. <https://doi.org/10.1109/MC.2021.3137227>
- Yokoyama, H. (2019). *Machine learning system architectural pattern for improving operational stability*. 267–274. Hamburgo, Alemania: IEEE. <https://doi.org/10.1109/ICSA-C.2019.00055>

ANEXOS

A. Modelo relacional de la base de datos

El modelo relacional se obtuvo en base al modelo entidad relación definido en la fase de diseño. Este modelo presenta una versión reducida donde solo se toman las relaciones y tablas más importantes para el sistema. Se ha omitido las tablas creadas por django admin relacionada a aspectos administrativos. Entre las definiciones mas importantes se encuentran `cart_product`, `cart_user_product_interaction`, `auth_user`, y `cart_user_recommendation`.

La tabla `cart_user_recommendation` almacena la lista de productos que han sido recomendados a los usuario esto en el atributo `'recommendations'`. Por otro lado, la tabla `cart_user_product_interaction` conserva las interacciones de los usuarios con los productos del sistema, donde la tupla `'user_id'` y `'producto_id'` debe aparecer solo una vez en esta tabla, cada vez que el usuario interactúe con un producto, el atributo `'last_seen'` se va a actualizar. Esta última información será usada para construir la matriz de adyacencia que representa el grafo de interacción.

B. Formato de cuestionario para los usuarios del e-commerce



REPUBLICA BOLIVARIANA DE VENEZUELA
UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA
VICERRECTORADO ACADÉMICO
COORDINACIÓN GENERAL DE PREGRADO
PROYECTO DE CARRERA: INGENIERIA EN INFORMATICA
CUESTIONARIO PARA SER APLICADO A LOS USUARIOS DEL E-
COMMERCE

¿Qué tan fácil fue para ti encontrar productos relevantes con la ayuda del sistema de recomendación?

- 1: Muy difícil
- 2: Difícil
- 3: Neutral
- 4: Fácil
- 5: Muy fácil

¿Qué tan precisas fueron las recomendaciones proporcionadas por el sistema en relación con tus preferencias?

- 1: Muy inexactas
- 2: Inexactas

3: Neutral

4: Precisas

5: Muy precisas

¿Qué tan satisfecho estás con la variedad de productos recomendados por el sistema?

1: Muy insatisfecho

2: Insatisfecho

3: Neutral

4: Satisfecho

5: Muy satisfecho

¿Qué tan probable es que recomiendes este sistema de recomendación a otras personas?

1: Muy improbable

2: Poco probable

3: Neutral

4: Probable

5: Muy probable

C. Respuestas emitidas por los encuestados

Figura 52. Respuestas emitidas por los usuarios.

¿Qué tan fácil fue para ti encontrar productos relevantes con la ayuda del sistema de recomendación?	¿Qué tan precisas fueron las recomendaciones proporcionadas por el sistema en relación con tus preferencias?	¿Qué tan satisfecho estás con la variedad de productos recomendados por el sistema?	¿Qué tan probable es que recomiendes este sistema de recomendación a otras personas?
Fácil	Precisas	Satisfecho	Probable
Muy Fácil	Muy precisas	Muy satisfecho	Muy probable
Fácil	Precisas	Muy satisfecho	Muy probable
Muy Fácil	Muy precisas	Muy satisfecho	Muy probable
Muy Fácil	Muy precisas	Muy satisfecho	Muy probable
Muy Fácil	Neutral	Satisfecho	Probable
Muy Fácil	Muy precisas	Muy satisfecho	Muy probable
Muy Fácil	Precisas	Muy satisfecho	Muy probable
Fácil	Precisas	Satisfecho	Muy probable
Muy Fácil	Muy precisas	Muy satisfecho	Muy probable
Fácil	Precisas	Muy satisfecho	Muy probable
Muy Fácil	Muy precisas	Muy satisfecho	Muy probable
Muy Fácil	Precisas	Muy satisfecho	Muy probable
Fácil	Precisas	Satisfecho	Probable
Muy difícil	Precisas	Satisfecho	Probable
Muy Fácil	Muy precisas	Muy satisfecho	Muy probable
Fácil	Precisas	Satisfecho	Muy probable
Fácil	Precisas	Muy satisfecho	Muy probable
Fácil	Precisas	Satisfecho	Muy probable
Fácil	Neutral	Muy insatisfecho	Muy improbable

D. Caso de uso Consultar productos

Se encuentra el caso de uso enfocado en la consulta y filtrado de los productos, este proceso es realizado por los usuarios autenticados, los cuales deben poder realizar operaciones tales como interactuar con los productos y filtrar por nombre, categoría o marca. En la [Tabla 6](#) se muestran los detalles del proceso.

Tabla 6. Descripción del caso de uso de gestión de carro de compras.

Nombre del CU	Consultar productos
Actor	Usuario
Descripción	Proceso a través del cual el usuario puede interactuar con los productos del e-commerce.
Pre-condiciones	1. El usuario debe haber ingresado al sistema. 2. El usuario debe estar autenticado.
Post-condiciones	1. El histórico de productos vistos debe estar actualizado.

Flujo normal	Pasos	Acción
	1	Filtrar productos de acuerdo al nombre, categoría, o marca.
	2	El sistema devuelve el listado de productos
	3	Usuario hace click sobre un producto.
	4	El sistema almacena la interacción usuario-producto si no existe.
	5	El sistema retorna los detalles del producto.
Flujo alternativo	Pasos	Acción
	1.a	Filtrar productos de acuerdo al nombre, categoría, o marca.
	2.a	No existe ningún producto con dichas especificaciones, retornar lista vacía.
	1.b	Usuario hace click sobre un producto de la lista de recomendación
	2.b	El sistema almacena la interacción usuario-producto si no existe.
	3.b	El sistema retorna los detalles del producto.

E. Manual de usuario del sistema



**REPUBLICA BOLIVARIANA DE VENEZUELA
UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA
VICERRECTORADO ACADÉMICO
COORDINACIÓN GENERAL DE PREGRADO
PROYECTO DE CARRERA: INGENIERIA EN INFORMATICA
MANUAL DE USUARIO DEL SISTEMA**

En el presente manual se detalla como los usuarios del sistema interactúan con el modelo de recomendación a través de una plataforma de e-commerce. Se abarca las rutas de navegación, y las interfaces de usuario necesarias para capturar la información de los usuarios y mostrar las recomendaciones personalizadas.

Ruta de navegación del sistema

En la [Figura 53](#) se puede observar la estructura jerárquica de las rutas del sitio web de comercio electrónico.





Figura 53. Mapa de navegación del sistema e-commerce

Interfaces graficas de usuario

En esta sección se muestran las secciones más importantes del sitio web de comercio electrónico.

Registro del usuario

Por medio de esta interfaz los usuarios podrán darse de alta en el sistema para poder realizar compras e interactuar con los productos de la tienda, así como obtener recomendaciones personalizadas. En la [Figura 54](#) se puede observar el formulario de registro en el sistema.



Sign up

Correo electrónico*

Correo electrónico

First Name*

Nombre

Apellido*

Apellido

Cédula*

Cédula debe estar en formato V-### o E-###

Dirección*

Dirección de residencia


SIGN UP

[Ya tienes una cuenta?](#)

Figura 54. Formulario de registro en el sistema

Inicio de sesión

A través de la pantalla de inicio de sesión el usuario podrá autenticarse en el sistema para poder utilizar los servicios de la plataforma. En la [Figura 55](#) se puede observar el formulario de inicio de sesión.



Sign in

Correo electrónico*

Correo electrónico

DNI*

DNI on format V-### or E-###

☐ Recordarme

SIGN IN

[Create new account](#)

Figura 55. Formulario de inicio de sesión.

Pantalla de inicio

Es la pantalla de inicio del sistema, desde esta interfaz los usuarios autenticados podrán visualizar los productos recomendados de acuerdo a sus histórico de interacciones previo. En la [Figura 56](#) se puede observar un carrusel con los elementos que podrían interesarles al usuario objetivo.




Figura 56. Página de inicio de la plataforma con recomendaciones para el usuario.

Pantalla de catalogo del e-commerce

A través de esta interfaz los usuarios podrán consultar los productos del sistema. En esta página los usuarios pueden filtrar los elementos por categoría o buscar por nombre. En la [Figura 57](#) se muestra el listado de elementos para la categoría de cámaras fotográficas.




Figura 57. Listado de productos del e-commerce para la categoría de cámaras.

Pantalla de detalles del producto

En la pantalla de detalles del producto se podrá ver especificaciones tales como el color y tamaño (Si estan disponibles), y la cantidad disponible en stock, además, se podrá seleccionar el número de unidades que se desean agregar al carro de compras.




Figura 58. *Página de detalles del producto.*

F. Manual del sistema



**REPUBLICA BOLIVARIANA DE VENEZUELA
UNIVERSIDAD NACIONAL EXPERIMENTAL DE GUAYANA
VICERRECTORADO ACADÉMICO
COORDINACIÓN GENERAL DE PREGRADO
PROYECTO DE CARRERA: INGENIERIA EN INFORMATICA
MANUAL DEL SISTEMA**

En el presente manual se detallan los aspectos técnicos del sistema de recomendación basado en grafos de interacción abarcando detalles sobre los requerimientos técnicos, despliegue, medidas de rendimiento, y el ajuste de parámetros para obtener un buen rendimiento predictivo. Este manual está dirigido a los desarrolladores y científicos de datos que deseen profundizar en el tema. El código fuente completo está disponible en el repositorio de GitHub: <https://github.com/FabianT1498/e-commerce>.

Requisitos del hardware

En esta sección se detallan las especificaciones de hardware mínimas y recomendadas para ejecutar el sistema en un entorno local. Estos requisitos aseguran un rendimiento adecuado durante el desarrollo, las pruebas y la operación del sistema de recomendación.

Tabla 7. Requerimientos para la ejecución del sistema en un entorno local

Tipo	Mínimo	Recomendado
CPU	• AMD A6-4400M APU • Intel Core i3 de cuarta generación o superior. • AMD Ryzen 3.	• Intel Core i5 de sexta generación o superior. • AMD Ryzen 5 (serie 2000 o superior). • Apple M1 (para entornos Mac).
Almacenamiento	10 GB libres en disco SSD	30 GB libres en disco SSD

Requisitos para desplegar el sistema

En esta sección se detallan las tecnologías y servicios necesarios para ejecutar el sistema de recomendación. Se presentan los requisitos específicos según el entorno de ejecución.

Tabla 8. Requerimientos para el despliegue del sistema

Entorno	Requerimientos	Versión
Local	Docker	Windows: Docker desktop 4.28.0 Linux: Docker Engine 27.4.0
	Docker Compose	Docker compose V2
Plataforma en la nube (Render)	Servicio de PostgreSQL	PostgreSQL 16 Plan: standard
	Servicio de cron job	Plan: starter
	Servicio web	Plan: starter

Despliegue del sistema en entorno local

La instalación del sistema en un entorno local permite configurar y ejecutar el sistema de recomendación directamente en tu máquina. Este

proceso es ideal para pruebas, desarrollo, y ajustes previos al despliegue en un entorno de producción. A continuación, se detallan los pasos necesarios para preparar el entorno local y garantizar el correcto funcionamiento del sistema.

1. Instalar Docker, si está bajo un entorno Linux (Ubuntu 20.04) debe ejecutar los siguientes comandos

```
sudo apt-get update  
  
sudo apt-get install docker-ce docker-ce-cli \ containerd.io  
docker-buildx-plugin docker-compose-plugin
```

En el caso de Windows se debe instalar Docker Desktop a través del instalador disponible en el sitio web de Docker.

2. Para construir los contenedores y levantar los servicios de la aplicación se debe ejecutar el siguiente comando en el cmd (Windows) o en el bash (Linux). El flag *-d* establece que los servicios van ejecutarse en segundo plano.

```
docker-compose up -d
```

3. Definir las variables de entorno en el archivo *.env*
4. Ingresar al *bash* del contenedor *ecommerce*. Para ello se debe utilizar el siguiente comando:

```
docker exec -it ecommerce bash
```

5. Instalar la utilidad *cron* para programar las tareas del sistema.

```
sudo apt-get install cron
```

6. Crear una tabla de tareas que va a ser gestionada por el proceso de *cron*.

```
crontab -e
```

7. Ejecutar el siguiente comando para agregar la tarea encargada de la ejecución del sistema de recomendación a la tabla de procesos gestionados por cron.

```
python manage.py crontab add
```

8. Abrir *localhost:8000* en el navegador web para comenzar a utilizar el sitio web.

Despliegue del sistema en la nube

Para desplegar el sistema en la nube, es indispensable contar con una cuenta activa en la plataforma Render. Una vez creada la cuenta, se deben seguir los pasos detallados a continuación para configurar y ejecutar correctamente el sistema en este entorno.

1. Crear un archivo llamado *render.yaml* donde se va a definir los servicios a utilizar. En este archivo, es necesario especificar el plan que se utilizará para cada servicio, el repositorio de Github donde está alojado el código, la rama que será desplegada en producción, y los servicios adicionales como base de datos.
2. En el *dashboard* de Render se debe seleccionar la opción *New Blueprint Deployment*, y seguir las instrucciones para vincular el archivo *render.yaml*.

Evaluación del rendimiento del modelo de recomendación

Se han implementado dos comandos en el servicio *ecommerce* para calcular las métricas ROC-AUC y Precision@k, que evalúan el rendimiento predictivo del sistema de recomendación. Las instrucciones para ejecutar los comandos se presentan a continuación:

1. Para poner en funcionamiento los servicios de la aplicación se debe ejecutar el siguiente comando en la cmd (Windows) o en la bash (Linux), el flag *-d* establece que los servicios van ejecutarse en segundo plano.

```
docker-compose up -d
```

2. Ingresar al *bash* del contenedor *ecommerce* el cual ejecuta el servicio web. Para ello se debe utilizar el siguiente comando:

```
docker exec -it ecommerce bash
```

3. Ejecutar el comando para obtener la medida ROC-AUC, el resultado del índice será mostrado en la terminal.

```
python manage.py calculate_model_auc
```

4. Ejecutar el comando para obtener la medida Precision@K, el resultado será almacenado en un archivo llamado result.csv en la carpeta *data* ubicada en la raíz del proyecto.

```
python manage.py test_model_precision
```

Diagnóstico y ajuste del modelo de recomendación

En esta sección se presentan los procedimientos necesarios para identificar y corregir posibles problemas en el modelo de recomendación. Se abordan aspectos clave del procesamiento de datos, como la normalización y el manejo de valores atípicos, así como la optimización de hiperparámetros del modelo. Estas estrategias buscan mejorar el rendimiento predictivo y garantizar que el sistema ofrezca recomendaciones precisas y relevantes para los usuarios.

- Verificar si hay valores atípicos en la distribución de los datos de las variables utilizadas para alimentar el modelo, de ser verdadero, se debe tomar la decisión de cómo tratar los valores que se consideran anormales.
- Normalizar la distribución de los datos de las características utilizadas por el modelo.
- Determinar el número de clústeres ideal para el algoritmo K – means, para posteriormente ajustar el parámetro en el algoritmo.
- Ajustar el parámetro de dispersión γ (Gamma) del algoritmo de similitud RBF Kernel, valores altos de γ hacen que solo los vectores de atributos muy similares tengan una similitud significativa, lo que enfatiza relaciones locales. Por el contrario, valores bajos permiten identificar

similitudes más globales, abarcando vectores con diferencias más amplias.

- Modificar los parámetros α (alfa) y β (beta) para regular el impacto de las matrices complementarias durante el proceso de factorización de matrices no negativas. Al establecer valores más altos para estos parámetros se le dará más peso a las matrices de comunidad y similitud de atributos respectivamente, por el contrario, si los valores de estos parámetros son bajos se le dará mas peso a la topología de la red.
- Incrementar el número de iteraciones en la factorización de matrices no negativas asegura una mejor convergencia de las matrices subyacentes, lo que permite obtener resultados más estables y precisos en el modelo.